



**Modelización del hábitat y
vulnerabilidad climática del *Abies
pinsapo* Boiss: Comparativa entre
aproximaciones paramétricas y
Machine Learning**

Francisco Javier López León



Modelización del hábitat y vulnerabilidad climática del *Abies pinsapo* Boiss: Comparativa entre aproximaciones paramétricas y Machine Learning

Francisco Javier López León

Memoria presentada como parte de los requisitos
para la obtención del título de Grado en Estadística
por la Universidad de Sevilla.

Tutorizada por

Prof. Agustín Riscos Núñez

Prof. Miguel Ángel Collado Aliaño

Agradecimientos

En primer lugar, deseo expresar mi más sincero agradecimiento a los profesores de la Facultad de Matemáticas de la Universidad de Sevilla, por haberme transmitido todos los conocimientos y la pasión por la ciencia de datos durante estos años de grado.

A mi familia, especialmente a mis padres y mi hermana, por su apoyo incondicional, su paciencia, por ser el pilar constante que me ha sostenido y motivado en cada etapa de mi vida y por hacerme la persona que soy. Sin ellos, este logro no habría sido posible.

A mis compañeros de grado y amigos, especialmente a Sergio, Miguel, Valdés, Montero, Alejandro y Cristóbal, con quienes he compartido infinitas horas de estudio, dudas y momentos inolvidables que han hecho de esta etapa universitaria una experiencia maravillosa.

A todos ellos, mi más profunda gratitud.

Resumen

El pinsapo (*Abies pinsapo* Boiss.) es una conífera relictas amenazada, endémica del sur de la Península Ibérica. Según el Ministerio para la Transición Ecológica, se enfrenta a la extirpación para finales de siglo. Mediante un enfoque metodológico cuantitativo y de modelización predictiva espacial, este estudio evalúa una aproximación paramétrica (GLM) frente a dos algoritmos de *Machine Learning* (*Random Forest*, RF; y *Gradient Boosting Machine*, GBM) para delimitar su nicho ecológico y proyectar su viabilidad a 2050.

Se aplicó un estricto filtrado a los registros de GBIF (Global Biodiversity Information Facility), excluyendo especímenes ornamentales para restringir el análisis a su distribución natural original. El protocolo incluyó un umbral espacial de 500m, *thinning* ($n = 101$) y control de multicolinealidad (VIF). Los modelos se entrenaron con pseudo-ausencias (1:1) y se evaluaron mediante Validación Cruzada por Bloques Espaciales (*Spatial Block CV*) para evitar la autocorrelación.

Aunque el GBM alcanzó el máximo rendimiento matemático ($AUC = 0.972$), exhibió una marcada polarización cartográfica y sobrepredicción ecológica en el espacio geográfico debido a su extrema dependencia de las condiciones térmicas. En contraste, mediante técnicas de interpretabilidad (Curvas PDP), *Random Forest* acotó fielmente el nicho realizado y demostró una excepcional transferibilidad al predecir de forma ciega el refugio rifeño de su especie vicariante (*A. marocana*). Finalmente, las proyecciones a 2050 pronostican el colapso del hábitat andaluz y un "espejismo ecológico" inalcanzable en el noroeste. Estos hallazgos urgen a diseñar estrategias de conservación *ex situ* y migración asistida para evitar la extinción del taxón.

English Abstract

The Spanish fir (*Abies pinsapo* Boiss.) is an endangered relict conifer endemic to the southern Iberian Peninsula. According to the Ministry for the Ecological Transition, it faces extirpation by the end of the century. Through a quantitative methodological and spatial predictive modeling approach, this study evaluates a parametric model (GLM) against two Machine Learning algorithms (*Random Forest*, RF; and *Gradient Boosting Machine*, GBM) to delineate its ecological niche and project its viability to 2050.

A strict filtering process was applied to the Global Biodiversity Information Facility (GBIF) records, excluding ornamental specimens to restrict the analysis to its original natural distribution. The protocol included a 500m spatial threshold, spatial *thinning* ($n = 101$), and multicollinearity control (VIF). Models were trained with pseudo-absences (1:1 ratio) and evaluated using Spatial Block Cross-Validation (*Spatial Block CV*) to prevent spatial autocorrelation.

Although GBM achieved the highest mathematical performance (AUC = 0.972), it exhibited marked cartographic polarization and ecological overprediction in geographic space due to its extreme dependence on thermal conditions. In contrast, through interpretability techniques (PDP curves), *Random Forest* accurately delineated the realized niche and demonstrated exceptional transferability by blindly predicting the North African refuge of its vicariant species (*A. marocana*). Finally, 2050 projections forecast the collapse of the Andalusian habitat and an unreachable "ecological mirage" in the northwestern peninsula. These findings highlight the urgency of designing *ex situ* conservation strategies and assisted migration programs to prevent the taxon's extinction.

Declaración sobre el uso de Inteligencia Artificial

Para la revisión de estilo, depuración del código en R y optimización del formato final de este documento en LaTeX, se ha empleado la asistencia de modelos de Inteligencia Artificial Generativa. En todo momento, el diseño de la investigación, el análisis estadístico, la interpretación ecológica de los resultados y las conclusiones finales son obra original e íntegra del autor.

Índice general

Agradecimientos	I
Resumen	III
English Abstract	V
Declaración sobre el uso de Inteligencia Artificial	VII
Índice de figuras	XIII
Índice de Tablas	XV
1. Introducción	1
1.1. Contexto Biogeográfico: El género <i>Abies</i>	1
1.2. Estado de conservación del <i>Abies pinsapo</i>	2
1.3. Modelos de Distribución de Especies (SDM)	2
1.4. Objetivos	3
1.4.1. Objetivos Específicos	3
1.5. Estructura de la memoria	4

2. Origen y Tratamiento de los Datos	7
2.1. Recolección de datos de presencia (GBIF)	7
2.2. Variables Bioclimáticas y Topográficas (WorldClim)	8
2.3. Protocolo de limpieza y Curación de Datos	10
2.4. Generación de Pseudo-ausencias	11
3. Metodología y Modelización	13
3.1. Análisis de Correlación y Multicolinealidad (VIF)	13
3.2. Algoritmos de Clasificación	15
3.2.1. Regresión Logística (GLM)	15
3.2.2. Random Forest (RF)	16
3.2.3. Gradient Boosting Machine (GBM)	16
3.3. Estrategias de Validación del Modelo	17
3.3.1. Validación Cruzada Aleatoria (k -fold CV)	17
3.3.2. Validación Cruzada Espacial (Spatial Block CV)	17
3.4. Métricas de Evaluación de Rendimiento	18
3.4.1. Interpretabilidad de Modelos Complejos: Curvas de Dependencia Parcial (PDP)	19
3.4.2. Métricas de Evaluación Predictiva	19
4. Resultados y Discusión	21
4.1. Evaluación de Modelos (AUC y Matrices de Confusión)	21
4.1.1. Diagnóstico de Ajuste del Modelo Paramétrico (GLM)	24
4.2. Importancia de las Variables Predictoras	26
4.2.1. Análisis de Respuesta Ecológica: Comparativa RF y GBM	29

4.3.	Análisis de la Proyección Cartográfica	32
4.3.1.	Categorización Estratégica del Hábitat	35
4.4.	Discusión Estadística y Ecológica	36
4.4.1.	Representatividad de la muestra y potencia estadística	36
4.4.2.	El desafío de la escala: La incertidumbre espacial en alta montaña	37
4.4.3.	Análisis de Robustez: Ensayo con Validación Espacial	37
4.4.4.	Extrapolación del Hábitat Potencial a Escala Peninsular	41
4.4.5.	Transferibilidad Biogeográfica: El refugio del Rif (Marruecos)	43
4.5.	Proyecciones ante el Cambio Climático (Horizonte 2050)	44
4.5.1.	Justificación del Modelo y Escenarios Climáticos	44
4.5.2.	Resultados: Colapso Bético-Rifeño y el Espejismo del Norte	46
4.5.3.	Implicaciones para la Gestión Forestal	47
5.	Conclusiones	49
5.1.	Conclusiones científicas	49
5.2.	Limitaciones metodológicas y futuras líneas de investigación	50
5.3.	Reflexión personal y dificultades superadas	51
	Anexo: Código fuente en R para la Modelización Ecológica	53

Índice de figuras

3.1. Matriz de correlación de Pearson entre las variables bioclimáticas y la elevación.	14
4.1. Curvas ROC conjuntas tras la validación cruzada.	22
4.2. Gráficos de diagnóstico de los residuos para el modelo GLM.	26
4.3. Importancia de variables en el modelo GBM, evaluada mediante la métrica de Influencia Relativa (<i>Relative Influence</i>).	27
4.4. Importancia de variables en el modelo <i>Random Forest</i> , evaluada mediante la métrica de disminución media de exactitud (<i>Mean Decrease Accuracy</i>).	27
4.5. Importancia de variables en el modelo GLM, evaluada mediante el valor absoluto del estadístico <i>Z</i>	28
4.6. Curvas de Dependencia Parcial (PDP) para Random Forest (RF)	30
4.7. Curvas de Dependencia Parcial (PDP) para Gradient Boosting (GBM)	31
4.8. Proyección del hábitat mediante Regresión Logística (GLM).	33
4.9. Proyección del hábitat mediante Random Forest (RF)	34
4.10. Proyección del hábitat mediante Gradient Boosting Machine (GBM). .	34
4.11. Diseño experimental de Validación Cruzada por Bloques Espaciales. .	38
4.12. Distribución del estadístico AUC por modelo mediante validación cruzada espacial.	40

4.13. Comparativa gráfica de extrapolación a escala peninsular.	42
4.14. Transferibilidad climática espacial.	43
4.15. Proyección de idoneidad climática para el horizonte 2050 bajo el es- cenario moderado (SSP2-4.5).	45
4.16. Proyección de idoneidad climática para el horizonte 2050 bajo el es- cenario pesimista (SSP5-8.5).	46

Índice de Tablas

2.1. Conjunto completo de las 19 variables bioclimáticas procedentes de la base de datos WorldClim.	9
2.2. Composición analítica de la muestra tras el control de calidad métrica, previo a la aplicación del filtro de autocorrelación espacial (<i>thinning</i>).	10
3.1. Variables predictoras seleccionadas tras el análisis de multicolinealidad ($VIF < 5$).	15
4.1. Métricas de rendimiento comparadas para los tres modelos de distribución (<i>5-fold Cross-Validation</i>)	22
4.2. Matriz de confusión promedio del modelo GBM (5-fold CV). Se observa la tasa de falsos positivos más baja del estudio (1.5 %).	23
4.3. Matriz de confusión promedio del modelo <i>Random Forest</i> (5-fold CV).	24
4.4. Matriz de confusión promedio del modelo GLM (5-fold CV).	24
4.5. Métricas de bondad de ajuste del Modelo Lineal Generalizado (GLM).	24
4.6. Coeficientes y estadísticos paramétricos del Modelo Lineal Generalizado (GLM).	29
4.7. Comparativa de la capacidad predictiva entre el remuestreo aleatorio clásico y el ensayo de validación por bloques espaciales.	39

1 | Introducción

1.1 Contexto Biogeográfico: El género *Abies*

La distribución actual de la biodiversidad en la Península Ibérica no puede comprenderse sin mirar al pasado, concretamente a las severas oscilaciones climáticas del Pleistoceno. Durante los períodos glaciares, el avance de los hielos en el norte de Europa provocó un drástico descenso de las temperaturas y alteró los patrones de precipitación a nivel continental. Ante este escenario hostil, la Península Ibérica actuó como uno de los refugios climáticos más importantes del sur de Europa [1], ofreciendo condiciones más templadas que permitieron la supervivencia y migración hacia el sur de numerosas especies de flora eurosiberiana, entre ellas, los ancestros del género *Abies*.

Con la transición hacia el Holoceno y el posterior establecimiento del clima mediterráneo actual, el verdadero drama ecológico comenzó para el pinsapo (*Abies pinsapo* Boiss.). A medida que las temperaturas globales ascendían, las condiciones de humedad y frío estival que esta especie necesita desaparecieron de las zonas bajas. Incapaz de migrar de vuelta al norte debido a barreras geográficas, el pinsapo quedó atrapado en el sur, viéndose obligado a ascender altitudinalmente en busca de su nicho térmico. Hoy en día, es un auténtico "náufrago" climático restringido a pequeñas islas ecológicas de alta montaña en la Serranía de Ronda, Sierra de las Nieves, Sierra Bermeja y la Sierra de Grazalema [16].

1.2 Estado de conservación del *Abies pinsapo*

Debido a su extrema especialización, su escasa variabilidad genética y su distribución altamente fragmentada, el *A. pinsapo* está catalogado como "En Peligro" en la Lista Roja de especies amenazadas [14]. Esta especialización responde a adaptaciones fisiológicas a condiciones difíciles de encontrar en una latitud donde predomina el clima mediterráneo y sus formaciones de matorral xerofítico. En este contexto, su supervivencia pende de un delicado equilibrio: requiere una elevada pluviosidad invernal y temperaturas frescas que mitiguen el severo estrés hídrico del verano.

Desde el punto de vista de la ecología teórica, es imperativo distinguir entre los dos espacios que ocupa la especie. Por un lado, su **nicho realizado**, que representa el espacio materialmente habitado por las poblaciones actuales en los refugios béticos; y por otro, su **nicho potencial**, que abarca el espacio habitable donde las condiciones bioclimáticas permitirían su desarrollo pero que, por limitaciones históricas o geográficas, no ha llegado a ser colonizado. Esta extrema vulnerabilidad y dependencia de nichos muy específicos convierte al pinsapo en un bioindicador excepcional de los efectos del cambio climático, requiriendo herramientas estadísticas de alta precisión para anticipar su viabilidad futura [3, 19].

1.3 Modelos de Distribución de Especies (SDM)

Desde la perspectiva estadística, los Modelos de Distribución de Especies (SDM, por sus siglas en inglés) [5] permiten relacionar observaciones puntuales empíricas de una especie con variables ambientales continuas para inferir su idoneidad de hábitat. Sin embargo, la interpretación de estas predicciones debe enmarcarse en la teoría clásica del nicho ecológico de Hutchinson [13].

Hutchinson definió el *nicho fundamental* como el hipervolumen de condiciones abióticas en las que una especie puede sobrevivir y reproducirse fisiológicamente. No obstante, en la naturaleza, las especies se ven limitadas por interacciones bióticas (competencia, depredación) y barreras de dispersión, lo que reduce su espacio habitable al denominado *nicho realizado*. En el ámbito de la modelización espacial, dado que rara vez se dispone de todas las variables bióticas, los algoritmos proyectan lo que cartográficamente se conoce como *nicho potencial*.

La arquitectura matemática del algoritmo condiciona qué parte de ese espectro se

está capturando. Los modelos paramétricos tradicionales (como el GLM), al basarse en respuestas aditivas y lineales, tienden a trazar fronteras de decisión suaves y laxas, incrementando el riesgo de sobrepredicción espacial. Por el contrario, ciertas arquitecturas de Machine Learning basadas en árboles de decisión (como las estrategias de ensamblaje paralelo de Random Forest), resultan idóneas para ajustar un hipervolumen restrictivo en torno al espacio ambiental efectivamente ocupado, minimizando los errores de comisión. Comprender y modelizar con esta precisión las fronteras del pinsapo no es solo un ejercicio biogeográfico, sino una herramienta indispensable para diseñar estrategias de conservación efectivas frente al cambio climático.

1.4 Objetivos

El objetivo general es evaluar y comparar la robustez de un enfoque paramétrico (Regresión Logística - GLM) frente a dos potentes algoritmos no paramétricos de *Machine Learning* (*Random Forest* - RF; y *Gradient Boosting Machine* - GBM) para definir matemáticamente el nicho ecológico del *A. pinsapo* y proyectar su idoneidad de hábitat espacial.

1.4.1 Objetivos Específicos

Para alcanzar el objetivo general, se plantean las siguientes metas metodológicas y analíticas:

- Aplicar un protocolo estricto de limpieza y filtrado espacial sobre registros masivos de presencia (GBIF) y generar un conjunto balanceado de pseudo-ausencias (ratio 1:1) para evitar sesgos en el entrenamiento de los algoritmos.
- Analizar y corregir la multicolinealidad de las variables ambientales (temperatura, precipitación y altitud) mediante el cálculo del Factor de Inflación de la Varianza (VIF).
- Validar la capacidad predictiva y la verdadera generalización geográfica de los modelos mediante el contraste entre la Validación Cruzada Aleatoria clásica y la Validación Cruzada por Bloques Espaciales (*Spatial Block CV*).
- Interpretar la respuesta no lineal y el efecto marginal de las variables bioclimáticas aplicando herramientas de explicabilidad en Inteligencia Artificial (Curvas PDP).

- Generar cartografía contrastando la predicción del nicho potencial frente al nicho realizado actual, evaluando además su transferibilidad ecológica mediante la proyección en territorios análogos (Cordillera del Rif, Marruecos).
- Estimar la vulnerabilidad y el riesgo de contracción del hábitat idóneo de la especie bajo escenarios futuros de cambio climático.

1.5 Estructura de la memoria

La presente memoria se encuentra estructurada de manera lógica para guiar al lector a través de las fases fundamentales del proyecto:

- **Capítulo 1 (Introducción):** Enmarca el contexto biogeográfico del *Abies pinsapo*, su estado de conservación actual, la justificación teórica basada en la teoría del nicho de Hutchinson y los objetivos perseguidos.
- **Capítulo 2 (Origen y Tratamiento de los Datos):** Detalla el origen de las observaciones extraídas de GBIF y los predictores de WorldClim, así como los protocolos de curación de datos, control de incertidumbre espacial y balance de clases.
- **Capítulo 3 (Metodología y Modelización):** Describe las herramientas estadísticas e informáticas utilizadas, incluyendo el control de multicolinealidad (VIF), las arquitecturas de clasificación (GLM, Random Forest, GBM) y la **formulación metodológica y diseño geométrico** de la Validación Cruzada por Bloques Espaciales (*Spatial Block CV*).
- **Capítulo 4 (Resultados y Discusión):** Expone la evaluación cuantitativa basal de los modelos, la jerarquización de importancia de variables y su interpretabilidad mediante curvas PDP. De forma central, incluye el **ensayo de robustez y el análisis crítico de los resultados de la validación espacial** mediante diagramas de dispersión del AUC. Asimismo, abarca la extrapolación peninsular, la transferibilidad biogeográfica hacia Marruecos y las proyecciones de impacto ante el cambio climático con horizonte 2050.
- **Capítulo 5 (Conclusiones y Líneas Futuras):** Sintetiza los hallazgos científicos más relevantes, las limitaciones del diseño experimental y una reflexión personal sobre el proceso de investigación y las dificultades superadas.

Es fundamental destacar que, con el fin de garantizar la máxima transparencia, reproducibilidad y rigor analítico, el código fuente completo en lenguaje R utilizado para la

ingesta, filtrado espacial, modelización y proyección cartográfica de todos los resultados se encuentra detallado íntegramente en el *Anexo*, y alojado de forma abierta en un repositorio público de GitHub [17], el cual incluye el script reproducible, los datos y las instrucciones de ejecución.

2 | Origen y Tratamiento de los Datos

2.1 Recolección de datos de presencia (GBIF)

Los datos de presencia de *A. pinsapo* se obtuvieron de la infraestructura mundial de información en biodiversidad (*Global Biodiversity Information Facility*, GBIF) [10]. Esta plataforma permite el acceso a registros biológicos procedentes de diversas fuentes, desde herbarios históricos hasta observaciones de ciencia ciudadana¹.

La descarga inicial se parametrizó para el ámbito geográfico de España, exigiendo que todos los registros contuvieran coordenadas geográficas explícitas. Se obtuvo un volumen bruto de datos masivo, lo que supuso el punto de partida para el posterior filtrado de calidad estadística.

Para garantizar la reproducibilidad absoluta del flujo de trabajo analítico y evitar la dependencia de la latencia o conectividad con servidores externos, se implementó una arquitectura de caché local en el entorno de R. Los registros crudos extraídos mediante la API se almacenaron en formato nativo estático (.rds). Esta estructura permite que las ejecuciones sucesivas del código interactúen de forma instantánea con una base de datos inmutable, estandarizando el punto de partida del modelo.

Es sumamente importante destacar una consideración técnica operativa sobre el entorno de computación: la primera ejecución de este script requiere la descarga de colecciones de datos raster globales altamente pesadas. Debido al volumen de trans-

¹La extracción se realizó mediante consultas directas a la API de GBIF. Cabe destacar que, para garantizar la máxima reproducibilidad a largo plazo y la asignación de un DOI único al conjunto de datos, las futuras metodologías operativas deberían transicionar hacia el uso de solicitudes asíncronas tipo `occ_download()`, el estándar actual recomendado por la infraestructura.

ferencia de los servidores cartográficos, los tiempos de respuesta iniciales son significativamente elevados, superando con creces el límite de tiempo por defecto que R asigna a las conexiones de red. Para evitar interrupciones prematuras y fallos en la compilación de datos, resulta indispensable parametrizar el entorno modificando el límite de tiempo nativo mediante la instrucción `options(timeout = 300)` previo a la llamada de las funciones de descarga.

2.2 Variables Bioclimáticas y Topográficas (WorldClim)

Como predictores ambientales para modelizar el nicho ecológico, se utilizaron las 19 variables bioclimáticas de la base de datos WorldClim (versión 2.1) [7]. Estas variables representan tendencias anuales, estacionalidad y factores limitantes de temperatura y precipitación, proporcionando una visión multidimensional del clima. A continuación, se detalla el espectro bioclimático completo evaluado originalmente antes de someter los predictores a los filtros matemáticos de selección analítica.

Tabla 2.1: Conjunto completo de las 19 variables bioclimáticas procedentes de la base de datos WorldClim (versión 2.1).

Categoría	Código	Descripción Ecológica / Métrica
Temperatura (°C)	BIO1	Temperatura media anual.
	BIO2	Oscilación diurna media (Media mensual de Temp. máx. – Temp. mín.).
	BIO3	Isotermalidad (BIO2/BIO7 $\times$ 100).
	BIO4	Estacionalidad de la temperatura (Desviación estándar $\times$ 100).
	BIO5	Temperatura máxima del mes más cálido.
	BIO6	Temperatura mínima del mes más frío.
	BIO7	Oscilación térmica anual (BIO5 – BIO6).
	BIO8	Temperatura media del trimestre más húmedo.
	BIO9	Temperatura media del trimestre más seco.
	BIO10	Temperatura media del trimestre más cálido.
	BIO11	Temperatura media del trimestre más frío.
Precipitación (mm)	BIO12	Precipitación anual.
	BIO13	Precipitación del mes más húmedo.
	BIO14	Precipitación del mes más seco.
	BIO15	Estacionalidad de la precipitación (Coeficiente de variación).
	BIO16	Precipitación del trimestre más húmedo.
	BIO17	Precipitación del trimestre más seco.
	BIO18	Precipitación del trimestre más cálido.
	BIO19	Precipitación del trimestre más frío.

Junto a los datos climáticos, se incorporó un **Modelo Digital de Elevación (DEM)** procedente de la misión *Shuttle Radar Topography Mission* (SRTM) [6]. La inclusión de la elevación global es de vital importancia en especies de alta montaña como *A. pinsapo*, ya que la altitud actúa como una variable "proxy" de diversos gradientes ambientales que no siempre quedan capturados únicamente por las estaciones meteorológicas.

Todo el conjunto de datos (19 variables bioclimáticas + elevación) se estandarizó a una resolución espacial de 30 segundos de arco ($\sim 1 \text{ km}^2$). Técnicamente, se realizó un proceso de *resampling* para asegurar que la capa de elevación coincidiera exactamente

en extensión y geometría con el resto de predictores, conformando un *stack* ambiental de 20 capas, raster sobre el cual se ejecutó la extracción de información.

2.3 Protocolo de limpieza y Curación de Datos

Para transformar el dataset bruto en una muestra apta para la modelización estadística, se aplicó un protocolo de curación estricto:

- **Filtro Temporal:** Se eliminaron todos los registros históricos carentes de año de observación para asegurar la sincronía con las variables ambientales contemporáneas.
- **Control de Calidad Espacial:** Se seleccionaron únicamente registros con una incertidumbre de coordenadas inferior o igual a 500 metros. Como se ha discutido anteriormente, este umbral es crítico en entornos de alta montaña.
- **Filtrado Espacial (*Spatial Thinning*):** Para evitar el sesgo por autocorrelación espacial (zonas con sobre-muestreo), se aplicó un filtro de vecindad que permite un máximo de un registro por píxel de 1km^2 .

Tras aplicar los filtros de calidad temporal y el umbral de incertidumbre espacial ($\leq 500\text{ m}$), el conjunto de datos se redujo a una muestra de alta fiabilidad de 468 registros. Un análisis de los metadatos de esta muestra (Tabla 2.2) revela la profunda dependencia actual de los repositorios de biodiversidad respecto a la ciencia ciudadana, representando las observaciones humanas el 97 % del volumen total de datos válidos, frente al 3 % aportado por colecciones clásicas de herbario.

Naturaleza del Registro (GBIF)	Total	Porcentaje (%)
Observación Humana (<i>Human Observation</i>)	454	97.0
Espécimen Preservado (<i>Preserved Specimen</i>)	14	3.0
Total Pre-Filtro Espacial	468	100.0

Tabla 2.2: Composición analítica de la muestra tras el control de calidad métrica, previo a la aplicación del filtro de autocorrelación espacial (*thinning*).

Posteriormente, la aplicación del filtro espacial (*spatial thinning*) a una resolución de 1 km^2 redujo finalmente este conjunto a los 101 registros de presencia estrictamente independientes que alimentan los algoritmos.

2.4 Generación de Pseudo-ausencias

Dado que los Modelos de Distribución de Especies basados en algoritmos de clasificación (GLM, Random Forest y GBM) requieren datos binarios (0 y 1), y GBIF solo proporciona presencias, fue necesario generar datos de ausencia sintética o "pseudo-ausencias".

Para garantizar la robustez del modelo, se siguió un protocolo de diseño experimental:

1. **Buffer de Exclusión:** Se definió un área de exclusión de 2.000 metros alrededor de cada punto [12] de presencia para asegurar que ninguna pseudo-ausencia fuera generada en hábitats donde la especie está presente.
2. **Enmascaramiento Territorial y Muestreo Aleatorio:** Para evitar la generación de coordenadas anómalas en el mar o en regiones fuera del ámbito de estudio, se aplicó una máscara espacial (*mask*) utilizando los límites administrativos de Andalucía (extraídos de la base de datos global GADM). Las pseudo-ausencias se muestrearon de forma aleatoria estrictamente dentro de los píxeles continentales válidos de dicho polígono.
3. **Balance de Clases (Ratio 1:1):** Se generaron exactamente 101 pseudo-ausencias para igualar el número de presencias. Mantener un *dataset* balanceado ($n = 202$) es esencial en estadística para evitar que los algoritmos se sesguen hacia la clase mayoritaria durante el entrenamiento.

3 | Metodología y Modelización

3.1 Análisis de Correlación y Multicolinealidad (VIF)

En la fase de preprocesamiento, resulta imperativo evitar la introducción de predictores altamente correlacionados. La multicolinealidad ocurre cuando dos o más variables independientes en un modelo están linealmente relacionadas con un alto grado de precisión. En modelos paramétricos como la Regresión Logística, este fenómeno infla artificialmente la varianza de los coeficientes estimados, volviéndolos inestables, reduciendo la potencia estadística y dificultando la interpretación del efecto individual de cada variable sobre la idoneidad del hábitat.

Para cuantificar y mitigar este problema, se empleó el Factor de Inflación de la Varianza (VIF, por sus siglas en inglés). El VIF evalúa cuánto se incrementa la varianza de un coeficiente de regresión estimado debido a la colinealidad con el resto de predictores. Matemáticamente, el VIF para una variable j se define como:

$$VIF_j = \frac{1}{1 - R_j^2}$$

donde R_j^2 es el coeficiente de determinación (R-cuadrado) de una regresión lineal múltiple de la variable predictora j sobre todas las demás variables predictoras del modelo. Como regla heurística general en la modelización ecológica, un valor de $VIF > 5$ [24] indica un nivel crítico de colinealidad que compromete la parsimonia del modelo.

Como paso exploratorio preliminar al cálculo del VIF iterativo, se generó una matriz de correlación de Pearson (Figura 3.1) para visualizar las relaciones bivariadas entre las 19 variables bioclimáticas de WorldClim y la elevación topográfica.

Matriz de Correlación de Pearson - Variables Bioclimáticas




Figura 3.1: Matriz de correlación de Pearson entre las variables bioclimáticas y la elevación. Las tonalidades azules indican correlación positiva fuerte ($r \rightarrow 1$), mientras que las rojizas indican correlación negativa fuerte ($r \rightarrow -1$).

A la vista de la matriz de correlación, resulta evidente la fuerte redundancia de la información ambiental (presencia masiva de coeficientes $|r| > 0.8$). Este escenario obligó a aplicar un algoritmo de selección *stepwise* basado en el VIF, eliminando iterativamente las variables más colineales.

Observación 3.1. Durante el análisis automatizado de multicolinealidad, la variable topográfica de altitud (elevación) presentó una correlación negativa casi perfecta ($r \approx -0.94$) con variables de tipo térmico, concretamente con la BIO8 (Temperatura media del trimestre más húmedo). En consecuencia, el algoritmo iterativo *vifstep* procedió a su exclusión automática. Aunque esta decisión garantiza la estabilidad paramétrica y aísla el verdadero efecto termopluviométrico macroscópico, conlleva una pérdida inevitable de información sobre la micro-topografía (valles, umbrías y barrancos) que resulta vital para la supervivencia térmica de la especie a escala local.

Tras la aplicación automatizada del algoritmo de selección *stepwise* basado en el VIF, el conjunto inicial de predictores ambientales se redujo a tres variables bioclimáticas estrictamente no colineales. Estas variables (Tabla 3.1) constituyen el núcleo predictivo sobre el cual se entrenaron los modelos.

Código	Descripción Ecológica (WorldClim)
BIO3	Isotermalidad (Oscilación diurna media / Oscilación térmica anual * 100)
BIO8	Temperatura media del trimestre más húmedo (°C)
BIO15	Estacionalidad de la precipitación (Coeficiente de Variación)

Tabla 3.1: Variables predictoras seleccionadas tras el análisis de multicolinealidad (VIF < 5).

Cabe destacar una consideración metodológica fundamental: aunque los algoritmos basados en ensamblajes de árboles de decisión son inherentemente robustos frente a la multicolinealidad predictiva, en este estudio se decidió entrenar los tres algoritmos (GLM, RF y GBM) estrictamente con el mismo subconjunto de predictores no colineales. Esta restricción garantiza un marco comparativo justo para evaluar las diferencias arquitectónicas entre los modelos paramétricos y no paramétricos. Asimismo, asegura que las métricas de importancia de variables extraídas de los algoritmos basados en árboles (*Random Forest* y GBM) reflejen fielmente la verdadera influencia ecológica de cada factor, evitando la distorsión analítica que se produce cuando estos modelos reparten los pesos predictivos entre variables altamente correlacionadas.

3.2 Algoritmos de Clasificación

3.2.1 Regresión Logística (GLM)

Como aproximación paramétrica basal, se ajustó un Modelo Lineal Generalizado (GLM). Dado que la variable respuesta es dicotómica (presencia frente a pseudoausencia), se especificó una distribución de error binomial y una función de enlace *logit* [18]. Matemáticamente, la probabilidad de idoneidad del hábitat p se modeliza de la siguiente forma:

$$\text{logit}(p) = \ln \left(\frac{p}{1-p} \right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k$$

donde β_0 es el intercepto y β_k son los coeficientes asociados a cada variable bioclimática X_k . Este modelo paramétrico asume, por defecto, respuestas aditivas de la especie al gradiente ambiental. En términos ecológicos, el GLM tiende a sobrepredicir la idoneidad geográfica debido a la naturaleza lineal y aditiva de sus fronteras

de decisión, las cuales compensan laxamente las deficiencias locales de un predictor ambiental con los valores favorables de otro.

3.2.2 Random Forest (RF)

Para capturar las posibles relaciones no lineales y las interacciones complejas entre las variables ambientales sin necesidad de especificarlas a priori, se implementó el algoritmo *Random Forest* [4]. Se trata de un método de aprendizaje supervisado no paramétrico basado en ensamblajes (*ensembles*) de múltiples árboles de decisión.

El algoritmo introduce aleatoriedad estructural mediante la técnica de *bagging* (Bootstrap Aggregating):

1. Cada árbol de decisión se entrena con una submuestra aleatoria (con reemplazo) extraída del conjunto de datos original.
2. En cada nodo de división del árbol, solo se evalúa un subconjunto aleatorio de variables predictoras para determinar el corte idóneo, maximizando la reducción de la impureza de Gini.

La predicción final del modelo se obtiene promediando las probabilidades predichas por cada árbol individual. Al no asumir una distribución probabilística previa y ser altamente resistente al ruido empírico, *Random Forest* tiende a modelizar fronteras de decisión ortogonales mucho más estrictas, caracterizando de forma conservadora el espacio ambiental efectivamente ocupado por las poblaciones conocidas de *A. pinsapo*.

3.2.3 Gradient Boosting Machine (GBM)

Al igual que el *Random Forest*, el *Gradient Boosting Machine* (GBM) es un potente algoritmo de aprendizaje automático no paramétrico basado en ensamblajes de árboles de decisión [9]. Sin embargo, su arquitectura matemática difiere fundamentalmente en la estrategia de entrenamiento. Mientras que el *Random Forest* construye múltiples árboles independientes de forma paralela (técnica de *bagging*), el GBM utiliza una aproximación secuencial conocida como *boosting*.

En este enfoque, los árboles se construyen uno a uno. Cada nuevo árbol se entrena específicamente para predecir y corregir los errores (residuos) cometidos por el en-

samblaje de los árboles anteriores, optimizando iterativamente una función de pérdida mediante el algoritmo de descenso de gradiente. Esta capacidad de auto-corrección continua convierte al GBM en un algoritmo extraordinariamente preciso para optimizar la función de pérdida. No obstante, esta misma virtud estructural (boosting secuencial) lo hace propenso a desarrollar una hiper-sensibilidad paramétrica ante variables dominantes, lo que justifica la necesidad ineludible de someterlo a pruebas rigurosas de validación espacial para auditar su verdadera capacidad de generalización geográfica.

3.3 Estrategias de Validación del Modelo

Uno de los desafíos fundamentales en modelización estadística con conjuntos de datos ecológicos es el riesgo de sobreentrenamiento o *overfitting*. Para obtener una estimación insesgada de la capacidad de generalización de los modelos, se evaluaron dos enfoques de validación cruzada implementados en el entorno estadístico R [20] mediante el paquete *caret* [15].

3.3.1 Validación Cruzada Aleatoria (k -fold CV)

Como evaluación basal de rendimiento, se implementó una técnica de Validación Cruzada Aleatoria con un parámetro $k = 5$. El conjunto de datos balanceado ($n = 202$) se dividió de forma aleatoria en cinco subconjuntos. De manera iterativa, cada modelo (GLM, RF y GBM) se ajustó utilizando cuatro pliegues para el entrenamiento y el pliegue restante como conjunto de prueba (*test set*). Este proceso garantiza que cada observación sea utilizada tanto para el entrenamiento como para la validación, proporcionando una estimación de la precisión global del modelo. No obstante, en el contexto de datos espaciales, este método se asume únicamente como una métrica optimista de referencia.

3.3.2 Validación Cruzada Espacial (Spatial Block CV)

La validación aleatoria tradicional asume la independencia estadística de las observaciones. Sin embargo, los datos de presencia biológica están sujetos a la Primera Ley de la Geografía de Tobler [22], la cual postula que "todo está relacionado con

todo lo demás, pero las cosas cercanas están más relacionadas que las distantes". En la modelización climática, este principio se traduce en una fuerte autocorrelación espacial: dos observaciones de *A. pinsapo* separadas por escasa distancia compartirán un microclima casi idéntico. Si en un remuestreo aleatorio convencional un punto se asigna al entrenamiento y su vecino geográfico al conjunto de prueba, el modelo no estará demostrando capacidad de extrapolación, sino memorizando un patrón local (pseudo-replicación), lo que infla artificialmente métricas de bondad de ajuste.

Para mitigar este sesgo derivado de la autocorrelación espacial y evaluar la verdadera capacidad de generalización de los algoritmos, se implementó un marco de Validación Cruzada por Bloques Espaciales. Mediante el uso del paquete `blockCV`[23], el área de estudio se subdividió en cuadrículas operativas de 15×15 km. Bajo este diseño experimental, la partición de los datos no es aleatoria, sino geográfica: si un bloque se asigna al conjunto de prueba, el modelo debe predecir la idoneidad de esa zona basándose únicamente en el aprendizaje obtenido en bloques distantes. Esta estrategia es crítica para auditar la robustez de los ensamblajes basados en árboles (RF y GBM), ya que forzándolos a modelizar con alta penalización se permite cuantificar y mitigar el grado de sobreajuste (*overfitting*) latente.

3.4 Métricas de Evaluación de Rendimiento

Para cuantificar y comparar la eficacia de la Regresión Logística, el Random Forest y el GBM, se utilizaron métricas derivadas de la matriz de confusión y el análisis de sensibilidad:

- **AUC (Area Under the Curve):** Es la métrica principal de este trabajo. Representa el área bajo la curva ROC (*Receiver Operating Characteristic*) y mide la capacidad del modelo para distinguir entre presencias y ausencias. Un valor de 0.5 indica una clasificación aleatoria, mientras que un valor cercano a 1 indica una discriminación casi perfecta [8]. Para el análisis estadístico y representación gráfica de estas funciones se empleó la librería especializada `pROC` [21].
- **Sensibilidad (*Recall*):** Proporción de presencias reales que fueron correctamente identificadas por el modelo.
- **Especificidad:** Proporción de pseudo-ausencias reales que fueron correctamente descartadas.
- **Precisión Global (*Accuracy*):** Porcentaje total de predicciones correctas sobre el total de casos.

3.4.1 Interpretabilidad de Modelos Complejos: Curvas de Dependencia Parcial (PDP)

A diferencia de los enfoques paramétricos como la Regresión Logística (GLM), que proporcionan coeficientes interpretables y valores p para cada predictor, los algoritmos de ensamblaje como *Random Forest* operan como modelos de *caja negra*. Para no sacrificar la interpretabilidad ecológica en favor de la precisión predictiva, resulta imprescindible la aplicación de técnicas de Explicabilidad en Inteligencia Artificial (XAI).

Para comprender la respuesta no lineal del *A. pinsapo* frente a los gradientes ambientales, se calcularon Curvas de Dependencia Parcial (PDP, por sus siglas en inglés: *Partial Dependence Plots*). Matemáticamente, una curva PDP aísla el efecto marginal de una variable predictora específica sobre la probabilidad media de idoneidad del hábitat predicha por el modelo, manteniendo el resto de variables ambientales constantes en sus valores reales observados. El análisis de estas funciones marginales permite identificar umbrales de tolerancia (*thresholds*) fisiológica, picos de idoneidad y puntos de colapso probabilístico de la especie, lo que traduce el complejo hiperespacio matemático de los algoritmos en conocimiento biológico accionable.

Asimismo, la aplicación de técnicas de interpretabilidad XAI se extendió al *Gradient Boosting Machine* (GBM). Dado que tanto el RF como el GBM son modelos de *caja negra* basados en ensamblajes, la comparación de sus funciones de respuesta marginal es fundamental. Este análisis permite verificar si arquitecturas matemáticas distintas convergen en la identificación de los mismos umbrales de tolerancia fisiológica para el pinsapo, dotando a las conclusiones de una doble validación estadística.

3.4.2 Métricas de Evaluación Predictiva

Para cuantificar y comparar la capacidad predictiva de los algoritmos, se emplearon dos métricas de rendimiento complementarias: el Área Bajo la Curva (AUC) de la característica operativa del receptor (ROC) y el Estadístico de Habilidad Verdadera (*True Skill Statistic*, TSS).

Dado que el diseño experimental de este estudio implementó un ratio de pseudo-ausencias 1:1 ($n = 101$ presencias y $n = 101$ ausencias), se neutralizó el sesgo de prevalencia, garantizando que el estadístico AUC ofreciera una medida robusta e insesgada del rendimiento global de los modelos en todos los umbrales posibles.

No obstante, la literatura ecológica recomienda evaluar no solo la probabilidad continua, sino la precisión de la frontera de decisión final (el umbral de corte utilizado para generar la cartografía binaria) [2]. Para ello se incorporó el estadístico TSS, que evalúa el rendimiento del modelo en un umbral específico, penalizando de forma equitativa los errores de omisión y comisión. Matemáticamente, el TSS integra las métricas de Sensibilidad (Tasa de Verdaderos Positivos, TP) y Especificidad (Tasa de Verdaderos Negativos, TN), calculándose como:

$$TSS = Sensibilidad + Especificidad - 1 \quad (3.1)$$

Que, expresado en términos de la matriz de confusión empírica (donde FN son falsos negativos y FP falsos positivos), se define como:

$$TSS = \frac{TP}{TP + FN} + \frac{TN}{TN + FP} - 1 \quad (3.2)$$

El valor del estadístico TSS oscila en el intervalo $[-1, 1]$, donde un valor de $+1$ indica una predicción perfecta. En el contexto de este estudio, se consideraron con excelente capacidad predictiva aquellos modelos que superaron simultáneamente los umbrales de $AUC \geq 0.90$ y $TSS \geq 0.80$.

4 | Resultados y Discusión

4.1 Evaluación de Modelos (AUC y Matrices de Confusión)

Tras aplicar el protocolo de Validación Cruzada Aleatoria ($k = 5$), se evaluó la capacidad de generalización de los tres algoritmos. Para garantizar el máximo rigor estadístico, el rendimiento se cuantificó bajo dos enfoques metodológicos complementarios: el promedio de las métricas obtenidas en cada pliegue individual y el cálculo de una curva ROC global o *pooled* mediante la agregación conjunta de todas las predicciones.

El análisis del rendimiento medio a través de los cinco exámenes independientes (caret) sitúa al algoritmo *Gradient Boosting Machine* (GBM) como el modelo matemáticamente más robusto, alcanzando la mayor Área Bajo la Curva ($AUC = 0.975$). A escasas milésimas se situó la aproximación paramétrica del GLM ($AUC = 0.973$), seguida de cerca por el *Random Forest* ($AUC = 0.969$). Como se detalla en la Tabla 4.1, esta superioridad del GBM también se refleja en el estadístico TSS (0.901) y en su altísima capacidad para identificar correctamente las ausencias de la especie y evitar falsos positivos (Especificidad del 97.0 %). Por su parte, la aproximación del GLM destacó por ser el modelo con mayor tasa de acierto a la hora de detectar las presencias reales de la especie en el territorio (Sensibilidad del 95.1 %). Esta evaluación cuantitativa resulta fundamental como paso previo a la interpretación ecológica y cartográfica de las predicciones.

Tabla 4.1: Métricas de rendimiento comparadas para los tres modelos de distribución (*5-fold Cross-Validation*). Valores evaluados utilizando el umbral de corte de probabilidad estándar ($p = 0.5$).

Modelo	AUC	TSS	Sensibilidad	Especificidad
Gradient Boosting (GBM)	0.975	0.901	0.931	0.970
Modelo Lineal (GLM)	0.973	0.873	0.951	0.922
Random Forest (RF)	0.969	0.833	0.921	0.912

Por otro lado, la Figura 4.1 representa la curva ROC global (*pooled*), la cual agrupa simultáneamente las predicciones de todos los pliegues para trazar una única función de rendimiento.




Figura 4.1: Curvas ROC conjuntas (*pooled*) obtenidas tras la validación cruzada. Se observa un empate técnico absoluto entre las tres aproximaciones matemáticas al evaluar el conjunto global de predicciones.

Bajo este segundo enfoque métrico, los resultados convergen de nuevo en un empate técnico absoluto: *Random Forest* ($AUC = 0.966$), *GLM* ($AUC = 0.965$) y *GBM* ($AUC = 0.964$). Esta levísima discrepancia decimal entre la media de los pliegues y el cálculo de la curva global es un fenómeno estadístico común, atribuible a la varianza

posicional de los umbrales de decisión al agrupar los datos. En cualquier caso, ambas metodologías confirman una capacidad discriminativa sobresaliente para los tres modelos.

Al analizar el comportamiento de los modelos mediante la curva ROC global (*pooled*) frente a la media de las curvas individuales de los *folds*, se observa un fenómeno revelador. Mientras que el algoritmo GBM experimenta una caída más pronunciada en su AUC al integrar todos los datos (de 0.975 a 0.964), el modelo Random Forest mantiene un desempeño prácticamente constante (de 0.969 a 0.966). Esta diferencia es fundamental: la caída en el GBM sugiere una inestabilidad en la calibración de sus umbrales de probabilidad entre las distintas particiones geográficas, evidenciando una menor capacidad de generalización espacial. Por el contrario, la estabilidad del Random Forest demuestra una mayor consistencia en la estructura de sus probabilidades, consolidándolo como una herramienta más fiable y menos sujeta a sesgos posicionales, siendo por tanto la opción más robusta para una gestión forestal basada en la toma de decisiones conservadora.

Para diseccionar con mayor precisión este rendimiento, resulta fundamental analizar las matrices de confusión promedio (Tablas 4.2, 4.3 y 4.4). Mientras que el modelo paramétrico lineal (GLM) presenta un 4.0 % de falsos positivos, el GBM logra reducir la proporción de falsos positivos al 1.5 %. Sin embargo, es fundamental interpretar esta alta especificidad estadística con cautela. Dado que el diseño experimental evaluó el modelo frente a 101 pseudo-ausencias distribuidas de forma aleatoria por toda la geografía continental andaluza (un área de gran extensión), la probabilidad estadística de que los puntos de control recayeran exactamente en las áreas montañosas orientales donde el GBM sobrepredice es sumamente baja. Por tanto, este 1.5 % refleja una excelente capacidad discriminativa a nivel macro-regional, pero enmascara errores de comisión espaciales que solo se hacen evidentes mediante la evaluación cartográfica.

		Realidad (Referencia)	
		Ausencia (0)	Presencia (1)
Predicción	Ausencia (0)	48.5 %	3.5 %
	Presencia (1)	1.5 %	46.5 %

Tabla 4.2: Matriz de confusión promedio del modelo GBM (5-fold CV). Se observa la tasa de falsos positivos más baja del estudio (1.5 %).

		Realidad (Referencia)	
		Ausencia (0)	Presencia (1)
Predicción	Ausencia (0)	45.5 %	4.0 %
	Presencia (1)	4.5 %	46.0 %

Tabla 4.3: Matriz de confusión promedio del modelo *Random Forest* (5-fold CV).

		Realidad (Referencia)	
		Ausencia (0)	Presencia (1)
Predicción	Ausencia (0)	46.0 %	2.5 %
	Presencia (1)	4.0 %	47.5 %

Tabla 4.4: Matriz de confusión promedio del modelo GLM (5-fold CV).

Es importante señalar que las métricas reportadas en la Tabla 4.1 representan la media aritmética de los resultados obtenidos en los 5 pliegues de la validación cruzada, mientras que las Tablas 4.2-4.4 presentan la matriz de confusión agregada (sumatoria de predicciones), lo que explica las ligeras discrepancias decimales debido a la varianza entre pliegues.

4.1.1 Diagnóstico de Ajuste del Modelo Paramétrico (GLM)

Para evaluar numéricamente la calidad del ajuste, se extrajeron las métricas globales del modelo (Tabla 4.5).

Tabla 4.5: Métricas de bondad de ajuste del Modelo Lineal Generalizado (GLM).

Métrica	Valor	Grados de Libertad (gl)
Devianza Nula (<i>Null deviance</i>)	280.03	201
Devianza Residual (<i>Residual deviance</i>)	74.38	198
Criterio de Información de Akaike (AIC)	82.38	-

La reducción drástica entre la devianza nula (280.03) y la devianza residual (74.38) evidencia matemáticamente que las variables ambientales retenidas tras el filtrado

estricto del VIF logran explicar de forma robusta y altamente significativa el nicho climático del *A. pinsapo*, alejándose por completo de un escenario aleatorio.

La validez del ajuste paramétrico se evaluó mediante un análisis exhaustivo de los residuos (Figura 4.2), permitiendo verificar las asunciones del modelo binomial y la estabilidad de los coeficientes:

- **Residuals vs Fitted:** La distribución horizontal de los residuos de Pearson alrededor de la línea cero confirma la adecuada especificación de la función de enlace *logit*, descartando patrones de no linealidad persistentes [18].
- **Normal Q-Q:** Aunque se observa una ligera desviación en las colas para observaciones específicas (e.g., X3, X95), el comportamiento general se ajusta a lo esperado para una distribución de error binomial en muestras ecológicas [24].
- **Scale-Location:** La estabilidad de la línea de tendencia roja sugiere una varianza constante, indicando que el error de predicción no está correlacionado con la probabilidad de idoneidad estimada, dotando al modelo de una alta estabilidad.
- **Residuals vs Leverage:** Este diagnóstico confirma la ausencia de observaciones influyentes o *outliers* espaciales. Como se observa en la Figura 4.2, ninguna coordenada supera los umbrales de la Distancia de Cook (0.5 y 1.0), garantizando que los coeficientes paramétricos extraídos no presentan sesgos derivados de registros anómalos [8].




Figura 4.2: Gráficos de diagnóstico de los residuos para el modelo GLM. El gráfico inferior derecho confirma la ausencia de observaciones influyentes, al no superar ninguna la distancia de Cook de 1.

4.2 Importancia de las Variables Predictoras

El análisis de la contribución de las variables bioclimáticas revela un hallazgo sumamente interesante: existe una **divergencia metodológica** significativa entre los tres algoritmos al jerarquizar los factores limitantes del *A. pinsapo* (Figuras 4.4, 4.5 y 4.3). Este resultado subraya la importancia de no depender de un único modelo, ya que arquitecturas matemáticas distintas capturan matices ecológicos diferentes.




Figura 4.3: Importancia de variables en el modelo GBM, evaluada mediante la métrica de Influencia Relativa (*Relative Influence*).




Figura 4.4: Importancia de variables en el modelo *Random Forest*, evaluada mediante la métrica de disminución media de exactitud (*Mean Decrease Accuracy*).




Figura 4.5: Importancia de variables en el modelo GLM, evaluada mediante el valor absoluto del estadístico Z .

A diferencia de lo que cabría esperar, no existe un consenso absoluto. El modelo **GBM** sufre un claro desequilibrio paramétrico, identificando a la **Isotermalidad (BIO3)** como la variable con mayor influencia relativa (cercana al 60 %) y eclipsando el resto de predictores. Por el contrario, el **Random Forest** y el **GLM** coinciden en señalar a la **Estacionalidad de la precipitación (BIO15)** como el factor dominante.

Esta discrepancia matemática tiene profundas implicaciones ecológicas. Al concentrar su peso predictivo casi en exclusiva en el confort térmico, el *GBM* tiende a operar cartográficamente como un interruptor binario (efecto 0 o 1). Esto genera una sobrepredicción espacial en áreas con temperaturas invernales aptas, independientemente de si el régimen de precipitación estival actúa como un filtro letal. El *Random Forest*, gracias a su arquitectura democrática de ensamblaje (*bagging*), balancea mejor la contribución marginal de la precipitación y la temperatura, lo que permite trazar un mapa más coherente con la realidad de campo.

Para complementar este análisis visual de importancia de variables, resulta imprescindible examinar los coeficientes paramétricos extraídos por la Regresión Logística (Tabla 4.6). Esta tabla no solo confirma la significancia estadística de los predictores climáticos, sino que revela la dirección de su efecto sobre la idoneidad del hábitat.

Tabla 4.6: Coeficientes y estadísticos paramétricos del Modelo Lineal Generalizado (GLM).

Predictor	Estimación (β)	Error Est.	Valor Z	Valor p
(Intercepto)	15.0242	14.6705	1.024	0.30578
BIO3 (Isotermalidad)	-0.7121	0.3350	-2.126	0.03350 *
BIO8 (Temp. media trim. húmedo)	-0.7914	0.2760	-2.868	0.00413 **
BIO15 (Estacionalidad precip.)	0.3143	0.0741	4.244	< 0.001 ***

Niveles de significancia: *** $p < 0.001$, ** $p < 0.01$, * $p < 0.05$

Como se observa en los estimadores (β), la estacionalidad de la precipitación (BIO15) ejerce un efecto positivo y altamente significativo ($p < 0.001$) sobre la presencia de la especie. Por el contrario, tanto la isotermalidad (BIO3) como la temperatura media del trimestre más húmedo (BIO8) presentan coeficientes negativos, demostrando matemáticamente la extrema vulnerabilidad del *A. pinsapo* ante anomalías térmicas y el calentamiento de sus refugios invernales.

4.2.1 Análisis de Respuesta Ecológica: Comparativa RF y GBM

A diferencia de los modelos paramétricos como el GLM, los algoritmos basados en árboles de decisión no proporcionan coeficientes de regresión interpretables de forma directa. Al ser modelos de *caja negra*, su validación ecológica requiere el uso de Curvas de Dependencia Parcial (PDP) mediante la implementación del paquete *pdp* [11]. Estas curvas permiten aislar el efecto marginal de una variable ambiental específica sobre la probabilidad media de idoneidad predicha, revelando la naturaleza no lineal del nicho del *A. pinsapo*.




Figura 4.6: Curvas de Dependencia Parcial (PDP) del algoritmo *Random Forest*. Se observan transiciones abruptas en forma de escalón, típicas de arquitecturas basadas en árboles profundos. El eje de ordenadas (yhat) representa la probabilidad media de idoneidad del hábitat predicha (0 a 1).

El análisis del **Random Forest** (Figura 4.6) desvela comportamientos de umbral (*thresholds*) muy marcados y coherentes con los estimadores paramétricos observados:

- **BIO15 (Estacionalidad de la precipitación):** Muestra un drástico incremento probabilístico a medida que la estacionalidad aumenta, disparándose a partir del umbral del 55-60 % (esta variable representa el Coeficiente de Variación de la precipitación mensual expresado directamente en porcentaje) y alcanzando su máximo en torno al 70 %. Esto indica que el pinsapo es altamente dependiente de regímenes pluviométricos marcadamente estacionales, adaptado al patrón mediterráneo orófilo donde las precipitaciones se concentran de forma torrencial en los meses de invierno.
- **BIO3 (Isotermalidad):** Exhibe una respuesta de umbral extraordinariamente restrictiva. La probabilidad de presencia sufre un desplome abrupto y casi vertical al superar el valor del 39-40 %. Esta caída drástica confirma la sensibilidad extrema de la especie, penalizando severamente los entornos con alta isotermalidad y demostrando su incapacidad fisiológica para tolerar regímenes donde las temperaturas diurnas y nocturnas fluctúan excesivamente en comparación

con la oscilación anual.

- **BIO8 (Temperatura media del trimestre más húmedo):** Revela una severa pérdida de idoneidad cuando las temperaturas invernales superan los 10°C. Esta drástica caída de la probabilidad confirma matemáticamente la naturaleza montana de la especie y su exigencia innegociable de refugios con fríos persistentes en el trimestre más lluvioso, descartando zonas de menor altitud.

Para contrastar estos resultados y comprender la profunda divergencia en la jerarquización de la importancia de variables, se generaron las curvas PDP para el modelo GBM (Figura 4.7).




Figura 4.7: Curvas de Dependencia Parcial (PDP) del algoritmo *Gradient Boosting Machine* (GBM). Se aprecia una morfología errática y altamente volátil, reflejo de su hiper-sensibilidad estadística al gradiente térmico. El eje de ordenadas (yhat) representa la probabilidad media de idoneidad del hábitat predicha (0 a 1).

Como se observa en la Figura 4.7, la morfología de las curvas del GBM dista mucho de ser un gradiente suave; de hecho, presenta una forma escalonada aún más abrupta, volátil y errática que la del *Random Forest*. Esta agresividad visual es el reflejo directo de su arquitectura matemática de aprendizaje secuencial (*boosting*) y explica por qué este modelo priorizó la Isotermalidad (BIO3) con casi un 60 % de importancia.

Si observamos la respuesta marginal a la BIO3 en el GBM, el modelo traza picos y valles artificiales extremadamente estrechos (con un pequeño pico en el 39 % se-

guido de un desplome violento y rebotes erráticos a partir del 40 %). Ecológicamente, las curvas del GBM muestran transiciones marcadamente escalonadas producto de su estrategia de aprendizaje secuencial. Esto no debe interpretarse como un sobreajuste clásico al ruido muestral —ya que el modelo mantiene un rendimiento sobresaliente ante la validación cruzada espacial—, sino como una hiper-sensibilidad estadística que polariza las fronteras de decisión en torno a micro-variaciones del predictor dominante (BIO3).

Aunque en variables como la BIO8 (desplome brusco a los 10°C) o la BIO15 (disparo probabilístico escalonado a partir del 60 %) el GBM converge en los mismos grandes umbrales biológicos detectados por el RF, su excesiva sensibilidad confirma el aprendizaje de una regla macroclimática hiper-rígida. Mientras que la arquitectura democrática del *Random Forest* (*bagging*) balancea todos los predictores para extraer la verdadera tendencia ecológica subyacente (*nicho realizado*), el GBM exprime matemáticamente la temperatura hasta generar umbrales hiperespecíficos. Esto no constituye un sobreajuste tradicional (puesto que generaliza bien en bloques espaciales nuevos), sino el mapeo de un *nicho potencial* termocéntrico e hipertrofiado que ignora las letales restricciones hídricas reales.

4.3 Análisis de la Proyección Cartográfica

La proyección espacial de las probabilidades predichas por los modelos constituye la culminación visual del análisis estadístico. Tras aplicar la máscara territorial a las variables ambientales actuales, los resultados cartográficos revelan diferencias metodológicas sustanciales en cómo cada algoritmo interpola la idoneidad climática dentro del espacio geográfico andaluz.




Figura 4.8: Proyección del hábitat mediante Regresión Logística (GLM). Representación teórica del nicho potencial, mostrando una clara sobreestimación espacial.

El mapa generado mediante el modelo paramétrico GLM (Figura 4.8) presenta un patrón de idoneidad extenso y continuo. Desde una perspectiva biogeográfica, el modelo proyecta el *nicho potencial* del *A. pinsapo*. Al basarse en relaciones lineales y aditivas, el GLM tiende a generar una "falsa equivalencia" climática: compensa la falta de precipitación con la suavidad térmica de zonas de menor altitud. Esto provoca una clara sobreestimación de la idoneidad en sierras prelitorales y en amplias formaciones montañosas orientales (entorno de Sierra Nevada y Cazorla), donde la especie no habita debido a barreras históricas de dispersión y estrictos filtros edáficos.




Figura 4.9: Proyección del hábitat mediante *Random Forest* (RF). Ajuste estricto al nicho realizado en las sierras occidentales.




Figura 4.10: Proyección del hábitat mediante *Gradient Boosting Machine* (GBM). Al actuar como un interruptor térmico, el modelo incurre en sobrepredicción espacial, proyectando un nicho potencial hipertrofiado hacia las sierras orientales.

Por el contrario, aunque los algoritmos basados en aprendizaje automático ofrecen una mayor flexibilidad frente a las limitaciones del modelo lineal, una inspección visual detallada revela una divergencia ecológica fundamental entre ellos (Figuras 4.9 y 4.10).

Si bien el GBM muestra un rendimiento matemático superior en las métricas tanto globales como espaciales ($AUC = 0.970$), su proyección denota el impacto cartográfico de su estructura secuencial. Esta alta puntuación no responde a una modelización equilibrada de los factores ambientales, sino a su extraordinaria capacidad matemática para clasificar las muestras basándose de forma casi exclusiva en la BIO3. Al actuar en el espacio geográfico como un interruptor térmico, el GBM proyecta áreas de idoneidad que ignoran restricciones hídricas críticas, delimitando un nicho potencial hipertrofiado que abarca sectores de las cordilleras orientales andaluzas donde la especie está biológicamente ausente. Esta proyección visual evidencia que la bajísima tasa de falsos positivos (1.5 %) obtenida en la validación cruzada era, en parte, un artefacto derivado de la densidad del muestreo de pseudo-ausencias, demostrando que la matriz de confusión es una métrica "ciega" a la distribución espacial continua.

Frente a esto, el *Random Forest* se erige como el modelo cartográfico preferente. Gracias a la naturaleza democrática y conservadora de su arquitectura (*bagging*), balancea adecuadamente el peso de las restricciones térmicas y pluviométricas (BIO15). Esto le permite delimitar una frontera de decisión extraordinariamente restrictiva, eliminando falsos positivos y concentrando la idoneidad máxima en los reductos poblacionales históricos (Serranía de Ronda, Sierra de las Nieves y Grazalema). Esta fiabilidad del *Random Forest* para acotar de forma conservadora los verdaderos «puntos calientes» (*nicho realizado*) resulta vital para evitar la sobreestimación cartográfica y optimizar la asignación de recursos en futuras campañas de conservación.

4.3.1 Categorización Estratégica del Hábitat

Con el objetivo de traducir las probabilidades continuas (0 a 1) en una herramienta de gestión forestal directamente accionable, se procedió a discretizar las proyecciones cartográficas en tres categorías operativas de conservación:

- **Hábitat No Apto** ($p < 0.3$): Áreas con estrés hídrico estival o anomalías térmicas incompatibles con el desarrollo fisiológico de la especie.
- **Refugio Potencial** ($0.3 \leq p < 0.7$): Zonas de transición que podrían actuar como áreas de supervivencia bajo un manejo selvícola intensivo.

- **Núcleo de Alta Idoneidad** ($p \geq 0.7$): Territorios que garantizan la viabilidad demográfica natural del pinsapo.

Al aplicar esta clasificación, la divergencia metodológica se hace espacial y numéricamente evidente. Mientras que el modelo paramétrico (GLM) clasifica vastas extensiones de las cordilleras orientales andaluzas como «Núcleo de Alta Idoneidad», los algoritmos de Machine Learning muestran comportamientos contrastados. Por su parte, el Gradient Boosting Machine (GBM) tiende a categorizar amplias zonas orientales y adyacentes como óptimas, reflejando su extrema dependencia del gradiente térmico (BIO3) e ignorando el filtro letal de la sequía estival. Por el contrario, el modelo Random Forest penaliza de forma estricta el territorio, restringiendo la categoría de «Núcleo de Alta Idoneidad» a polígonos extremadamente concentrados y fieles a la realidad biológica en la región occidental (Serranía de Ronda, Sierra de las Nieves y Grazalema). Esta fiabilidad del Random Forest para acotar de forma conservadora los verdaderos «puntos calientes» (nicho realizado) resulta vital para evitar la sobreestimación cartográfica y optimizar la asignación de recursos en futuras campañas de conservación.

4.4 Discusión Estadística y Ecológica

Los resultados obtenidos permiten realizar una reflexión profunda sobre la intersección entre la modelización matemática y la realidad biográfica del *A. pinsapo*. A continuación, se discuten los pilares que sustentan la robustez del modelo y las limitaciones inherentes al diseño experimental.

4.4.1 Representatividad de la muestra y potencia estadística

Un factor determinante en el éxito de este estudio ha sido la disponibilidad de datos. Para construir Modelos de Distribución de Especies (SDM) con garantías de convergencia y estabilidad en los parámetros, es imperativo contar con un volumen de observaciones suficiente. En el caso del *A. pinsapo*, la riqueza de registros en bases de datos como GBIF ha permitido trabajar con una muestra final de alta calidad ($n = 202$ tras el filtrado), algo inusual en especies catalogadas en peligro crítico.

Esta abundancia de observaciones ha sido el "combustible" necesario para aplicar con éxito la Validación Cruzada de 5 pliegues, permitiendo que cada subconjunto de

entrenamiento sea lo suficientemente representativo de la variabilidad ambiental de la especie. Sin esta densidad de datos, los potentes algoritmos de *Machine Learning* basados en ensamblajes, como el *Random Forest* y el GBM, habrían tendido inevitablemente al sobreajuste frente a datos atípicos o a una varianza excesiva en sus predicciones por falta de patrones representativos.

4.4.2 El desafío de la escala: La incertidumbre espacial en alta montaña

A pesar de la alta precisión de los modelos ($AUC > 0.95$), es necesario realizar una autocrítica metodológica respecto al control de calidad espacial. En este trabajo, se estableció un umbral de incertidumbre de coordenadas de ≤ 500 metros. Si bien este valor es un estándar aceptado en estudios macroclimáticos, su aplicación en ecosistemas de alta montaña conlleva un riesgo estadístico latente.

En la orografía abrupta de la Serranía de Ronda o la Sierra de las Nieves, un error de 500 metros en la ubicación horizontal puede traducirse en un desplazamiento vertical drástico. Dada la pendiente del terreno, esa distancia puede suponer la diferencia entre una ladera de umbría (hábitat altamente idóneo) y el fondo de un valle o una cresta expuesta con condiciones térmicas y pluviométricas radicalmente distintas. Esta “borrosidad” espacial introduce un ruido en los datos climáticos extraídos de WorldClim que el modelo debe procesar. Es muy probable que la superioridad del Random Forest en este estudio se deba a su capacidad intrínseca para manejar estas interacciones complejas y no lineales derivadas de la microvariabilidad climática, donde el GLM, por su naturaleza aditiva y lineal, presenta mayores dificultades de ajuste. Como futura línea de investigación, la incorporación de variables micro-topográficas, tales como el Índice de Radiación Solar o la orientación de la ladera (umbría frente a solana), permitiría capturar estas dinámicas tridimensionales y refinar significativamente la resolución del modelo a escala local.

4.4.3 Análisis de Robustez: Ensayo con Validación Espacial

Para complementar la validación cruzada aleatoria y poner a prueba la verdadera capacidad de extrapolación de los modelos frente a la autocorrelación espacial, se ejecutó un ensayo estadístico adicional utilizando bloques espaciales (*Spatial Block Cross-Validation*). A diferencia del remuestreo aleatorio, donde los datos de entrena-

miento y prueba pueden ser geográficamente contiguos y compartir microclimas casi idénticos, la partición espacial divide el territorio en cuadrículas independientes (Figura 4.11).




Figura 4.11: Diseño experimental de Validación Cruzada por Bloques Espaciales. Las muestras se agrupan geográficamente para forzar al algoritmo a predecir la idoneidad en macizos montañosos aislados que no intervinieron en su fase de entrenamiento.

Este riguroso enfoque obliga a los algoritmos a entrenar, por ejemplo, con las subpoblaciones de la Serranía de Ronda, y examinarse intentando predecir la presencia en áreas distantes. Los resultados de este ensayo de extrapolación frente a la partición aleatoria clásica se detallan en la Tabla 4.7.

Algoritmo y Validación	AUC	Sensibilidad	Especificidad
Regresión Logística (GLM)			
- K-Fold Aleatorio	0.973	0.950	0.920
- K-Fold Espacial	0.955	0.948	0.942
Random Forest (RF)			
- K-Fold Aleatorio	0.969	0.980	0.920
- K-Fold Espacial	0.961	0.960	0.877
Gradient Boosting Machine (GBM)			
- K-Fold Aleatorio	0.975	0.975	0.930
- K-Fold Espacial	0.970	0.968	0.928

Tabla 4.7: Comparativa de la capacidad predictiva entre el remuestreo aleatorio clásico y el ensayo de validación por bloques espaciales.

Como era previsible, la introducción de barreras espaciales provoca una caída en el rendimiento de los tres modelos, cuantificando matemáticamente el grado de autocorrelación espacial latente en la muestra. Sin embargo, resulta de vital importancia ecológica observar que, a pesar del endurecimiento de la prueba, los algoritmos de *Machine Learning* (tanto *Random Forest* como GBM) logran mantener una superioridad predictiva global frente al modelo paramétrico GLM. Esto demuestra que las complejas interacciones capturadas por los ensamblajes de árboles no son un mero artefacto estadístico de sobreajuste local, sino una representación fidedigna y generalizable de las restricciones fisiológicas de la especie.

Para complementar los resultados globales de la tabla comparativa, la Figura 4.12 desglosa el rendimiento de los modelos a través de los bloques espaciales. Mientras que las métricas globales ofrecen la media aritmética, este diagrama de cajas resulta fundamental para evaluar la dispersión mediante la mediana y el rango intercuartílico.




Figura 4.12: Distribución del estadístico AUC por modelo mediante validación cruzada espacial. Las cajas representan el rango intercuartílico del rendimiento a través de los distintos bloques geográficos.

Como se puede observar, la mediana predictiva del Random Forest (RF) en el ensayo espacial experimenta un ascenso frente a la validación aleatoria. Sin embargo, su media de AUC global (Tabla 4.7) desciende. Esta aparente paradoja se explica por la presencia de un pliegue espacial anómalo (outlier inferior en torno a 0.89) que ensancha la caja del RF y arrastra el promedio hacia abajo. Matemáticamente, el Gradient Boosting Machine (GBM) logra mantener una caja ligeramente más compacta y una media superior. Como se evidenció en el análisis cartográfico, esta estabilidad del GBM ante bloques geográficos ciegos demuestra que su regla de clasificación basada en la temperatura es matemáticamente robusta y altamente transferible en el espacio macroclimático. La elección del *Random Forest* como modelo definitivo no responde, por tanto, a una superioridad matemática estricta —ya que el GBM demostró mayor capacidad de extrapolación pura—, sino a una decisión pragmática basada en la ecología aplicada. En la biología de la conservación y la gestión forestal de especies amenazadas, se debe aplicar el principio de precaución: el *Random Forest* ofrece una proyección cartográfica mucho más conservadora y cauta, penalizando de forma estricta el territorio que no cumple simultáneamente el equilibrio termopluviométrico y evitando así destinar esfuerzos de conservación a "falsos refugios" ecológicamente inviables.

4.4.4 Extrapolación del Hábitat Potencial a Escala Peninsular

Como demostración final de la solidez algorítmica y de su potencial aplicación en gestión forestal, se proyectó el modelo *Random Forest* espacialmente validado sobre la totalidad de la Península Ibérica, limitando el espacio predictivo exclusivamente a la superficie continental. Para respaldar la robustez de esta proyección cartográfica mediante validación externa, se ha realizado una comparativa gráfica directa entre la idoneidad climática predicha por la máquina y los muestreos reales presentes en GBIF.

Cabe señalar que esta proyección constituye un ejercicio de evaluación de la capacidad discriminativa del algoritmo frente a climas no representados en el entrenamiento. Si bien el modelo opera bajo condiciones de extrapolación —lo cual conlleva una incertidumbre estadística intrínseca discutida en la Sección 4.4.2—, el resultado cartográfico sirve como una prueba de estrés para confirmar que el modelo no incurre en una sobreestimación indiscriminada del hábitat.




Figura 4.13: Comparativa gráfica de extrapolación a escala peninsular. **Arriba:** Proyección de idoneidad climática del modelo *Random Forest*. **Abajo:** Distribución observada según registros históricos de alta precisión (GBIF). Se confirma la convergencia absoluta entre las predicciones del algoritmo y la realidad de campo.

El resultado cartográfico visualiza la extrema especialización de la especie y la precisión del modelo. A pesar de evaluar vastas extensiones montañosas en el norte peninsular, la Cordillera Cantábrica, los Pirineos o el Sistema Central, el algoritmo penaliza la idoneidad hasta valores nulos.

Al contrastar esta proyección con los registros empíricos de GBIF (Figura 4.13), se observa una convergencia absoluta: la probabilidad máxima se concentra exclusivamente en el "punto caliente" de las cordilleras béticas occidentales, solapándose milimétricamente con las presencias reales. Esta ausencia de falsos refugios a macro-escala confirma que el modelo no tiende a la sobrepredicción y ha capturado con éxito la huella termopluviométrica exacta que exige la viabilidad del *A. pinsapo*.

4.4.5 Transferibilidad Biogeográfica: El refugio del Rif (Marruecos)

Una de las pruebas metodológicas más exigentes para evaluar la robustez de un Modelo de Distribución de Especies (MDE) es su transferibilidad espacial (*spatial transferability*): la capacidad matemática del algoritmo para predecir hábitats idóneos en regiones geográficas que jamás ha "visto" durante su fase de entrenamiento. Para poner a prueba esta cualidad, se expandió la proyección climática del modelo *Random Forest* hacia el norte de África (Figura 4.14).




Figura 4.14: Transferibilidad climática espacial. El modelo, entrenado exclusivamente con datos de la Península Ibérica, detecta una alta idoneidad en la cordillera del Rif (Marruecos), identificando de forma ciega el refugio del *Abies marocana*.

Sin haber introducido un solo registro de presencia proveniente del continente africano, el algoritmo identificó con altísima probabilidad de idoneidad los enclaves montañosos de la cordillera del Rif, concretamente en el entorno del Parque Nacional

de Talassemtane. Biogeográficamente, este resultado es de una relevancia extraordinaria. El área de alta idoneidad detectada por el modelo cartografía con precisión milimétrica la distribución natural endémica del *Abies marocana* (el abeto marroquí).

El *A. marocana* es una especie vicariante del pinsapo, es decir, una especie hermana que divergió evolutivamente al quedar aislada geográficamente tras la apertura del Estrecho de Gibraltar, conservando unos requerimientos ecológicos casi idénticos. Que un algoritmo entrenado en la Serranía de Ronda sea capaz de "descubrir" el nicho de una especie críptica en otro continente constituye la prueba definitiva de que los predictores seleccionados y la arquitectura de ensamblaje empleada no han memorizado coordenadas locales, sino que han logrado decodificar el **nicho climático fundamental** de los abetos bético-rifeños.

4.5 Proyecciones ante el Cambio Climático (Horizonte 2050)

Tras haber validado la robustez del modelo mediante la transferibilidad espacial en Marruecos (Sección 4.4.5), nos enfrentamos al desafío definitivo: la transferibilidad temporal. Este ensayo evalúa la resiliencia del complejo biológico *Abies pinsapo* / *Abies marocana* ante el calentamiento global, proyectando su nicho climático hacia el año 2050.

4.5.1 Justificación del Modelo y Escenarios Climáticos

Para las proyecciones futuras, se optó por el algoritmo **Random Forest**. A pesar de que el *Gradient Boosting Machine* (GBM) presentó métricas ligeramente superiores, el Random Forest demostró en la extrapolación peninsular una actitud más conservadora y restrictiva, penalizando de forma más severa los falsos refugios. En un contexto de gestión y conservación, es imperativo utilizar modelos que no sobrepredigan la idoneidad futura.

Se proyectó el modelo sobre dos trayectorias socioeconómicas compartidas (SSP) del CMIP6 (*Coupled Model Intercomparison Project Phase 6*):

- **SSP2-4.5 (Escenario Moderado):** Representa una trayectoria de emisiones intermedias, donde las medidas de mitigación logran estabilizar el forzamiento radiativo.
- **SSP5-8.5 (Escenario Pesimista):** Representa un futuro impulsado por el desarrollo basado en combustibles fósiles, sin políticas climáticas adicionales.

Para ofrecer una visión integral de la vulnerabilidad de la especie, el espacio de proyección incluyó tanto la Península Ibérica como el norte de África (cordillera del Rif), evaluando el impacto sobre la totalidad de su nicho potencial conocido.




Figura 4.15: Proyección de idoneidad climática para el horizonte 2050 bajo el escenario moderado (SSP2-4.5). Se observa un drástico declive en las áreas de distribución actual (Andalucía y Rif) y el inicio del desplazamiento del nicho potencial hacia latitudes septentrionales.




Figura 4.16: Proyección de idoneidad climática para el horizonte 2050 bajo el escenario pesimista (SSP5-8.5). El colapso del hábitat en los núcleos bético-rifeños es casi total, acentuándose el "espejismo ecológico" de alta idoneidad en el noroeste peninsular.

Cabe destacar una limitación inherente a los algoritmos basados en árboles de decisión: su incapacidad matemática para extrapolar frente a climas anómalos o "novedosos" (*novel climates*) que excedan los umbrales de entrenamiento. Sin embargo, en el caso del *A. pinsapo*, esta restricción matemática no invalida la proyección biológica. El análisis de las Curvas de Dependencia Parcial (Sección 4.2.1) demostró que la probabilidad de idoneidad ya colapsa y alcanza valores nulos mucho antes de llegar a los extremos térmicos que proyecta el escenario 2050. Por tanto, aunque el modelo alcance su límite predictivo y mantenga el último valor conocido, este valor ya representa la extinción local de la especie, haciendo la predicción ecológicamente precisa.

4.5.2 Resultados: Colapso Bético-Rifeño y el Espejismo del Norte

Los resultados cartográficos revelan un panorama desolador en ambos escenarios, sugiriendo una vulnerabilidad crítica extrema (Figuras 4.15 y 4.16). En el escenario moderado, la idoneidad climática en los núcleos originarios de la Serranía de Ronda, Sierra de las Nieves, Grazalema y la cordillera del Rif sufre una contracción dramática. En el escenario pesimista, el colapso es prácticamente total, con la probabilidad de idoneidad cayendo a niveles marginales.

Sin embargo, el fenómeno más llamativo de estas proyecciones es la **migración latitudinal del nicho climático**. A medida que el sur de la Península se vuelve inhóspito, el modelo identifica la emergencia de un vasto territorio de alta idoneidad en el noroeste ibérico (interior de Galicia y norte de Portugal).

Desde la perspectiva de la biología de la conservación, este desplazamiento latitudinal representa un "**espejismo ecológico**". Aunque el noroeste peninsular (y puntualmente enclaves como Sierra Morena) puedan ofrecer en 2050 el régimen termopluviométrico que la especie demanda en la actualidad, el pinsapo se encuentra en un callejón sin salida evolutivo. Por un lado, la especie carece de la capacidad de dispersión natural necesaria para franquear las enormes barreras geográficas (como la depresión del Guadalquivir, sometida a estrés térmico severo). Por otro lado, la especie se enfrentaría a barreras edáficas insalvables: el *A. pinsapo* es un especialista calcícola y serpentínícola (peridotitas), por lo que la dominancia de sustratos silíceos (granitos, pizarras y cuarcitas) en estos nuevos "refugios climáticos" impediría su establecimiento real.

4.5.3 Implicaciones para la Gestión Forestal

Estas proyecciones confirman que las poblaciones naturales de abetos bético-rifeños entrarán en una severa fase de "deuda de extinción" climática. No obstante, es imperativo interpretar este colapso con la cautela que exige la escala de trabajo. Dado que la exclusión analítica de la altitud y el uso de píxeles de 1 km² promedian la rugosidad del terreno, el modelo proyecta un colapso "macroclimático" que no tiene la resolución matemática suficiente para percibir los micro-refugios topoclimáticos (umbrías, dolinas y fondos de barranco muy profundos). La supervivencia *in situ* de la especie dependerá de la identificación milimétrica y protección silvícola de estos enclaves topográficos. Simultáneamente, ante la imposibilidad de una migración natural hacia los nuevos análogos climáticos del norte ibérico, la conservación integral requerirá el diseño urgente de estrategias de **migración asistida** y el fortalecimiento de bancos de germoplasma *ex situ*.

5 | Conclusiones

5.1 Conclusiones científicas

El desarrollo de este Trabajo de Fin de Grado ha permitido integrar técnicas avanzadas de curación de datos espaciales, modelización estadística y algoritmos de *Machine Learning* aplicados a la conservación de la biodiversidad. A partir del análisis del nicho ecológico del complejo bético-rifeño (*A. pinsapo* y *Abies marocana*), se extraen las siguientes conclusiones fundamentales:

1. **La calidad de los datos es el pilar de la inferencia espacial:** El filtrado riguroso de la base de datos masiva de GBIF, aplicando umbrales estrictos de incertidumbre (≤ 500 m) y técnicas de *spatial thinning*, ha demostrado que en la modelización de nichos es preferible sacrificar el volumen de la muestra (reduciéndola a $n = 101$ presencias) a cambio de maximizar la fiabilidad y mitigar el sesgo de autocorrelación espacial antes de entrenar a la máquina.
2. **Superioridad y complementariedad del *Machine Learning*:** La auditoría mediante Validación Cruzada por Bloques Espaciales (*Spatial Block CV*) demostró que los ensamblajes de árboles superan sistemáticamente al modelo paramétrico clásico (GLM). Mientras que el algoritmo *Gradient Boosting Machine* (GBM) destacó como el más robusto y estable cuantitativamente ($AUC = 0.970$ ante la extrapolación), el *Random Forest* demostró ser la herramienta cartográfica más conservadora, resultando ideal para acotar geográficamente el hábitat idóneo sin incurrir en sobrepredicción indiscriminada.
3. **Transferibilidad espacial y validación biogeográfica:** La extrapolación del modelo a escala macroclimática evidenció una precisión excepcional. Por un lado, la proyección peninsular coincidió milimétricamente con los registros independientes de GBIF, aislando los "análogos climáticos" del noroeste. Por otro

lado, la predicción ciega de alta idoneidad en la cordillera del Rif —refugio natural de la especie hermana *Abies marocana*— corrobora de forma empírica que el algoritmo no ha memorizado coordenadas locales, sino que ha decodificado la impronta bioclimática macroescala del linaje.

4. **Divergencia en la jerarquización de factores limitantes:** La comparativa de algoritmos reveló que distintas arquitecturas matemáticas capturan matices ecológicos complementarios. Mientras que el modelo GBM centró su capacidad de discriminación en el gradiente de Isotermalidad (BIO3), *Random Forest* y GLM priorizaron el estrés hídrico marcado por la Estacionalidad de la precipitación (BIO15). Esta constatación subraya el peligro de depender de un único algoritmo para interpretar respuestas ecológicas complejas.
5. **Alerta climática y necesidad de migración asistida:** Las proyecciones temporales hacia el horizonte 2050 (bajo los escenarios SSP2-4.5 y SSP5-8.5) pronostican un colapso crítico del hábitat en las sierras originarias andaluzas. El desplazamiento latitudinal de la idoneidad hacia el norte peninsular constituye un mero "espejismo ecológico", inalcanzable de forma natural por la especie. En consecuencia, el pinsapo entrará en una severa fase de deuda de extinción climática, lo que convierte a la identificación de micro-refugios topográficos y a las estrategias de migración asistida en imperativos categóricos para su conservación.

5.2 Limitaciones metodológicas y futuras líneas de investigación

A pesar de la robustez estadística y ecológica de los modelos generados, es imperativo reconocer ciertas limitaciones metodológicas inherentes al diseño experimental actual. Su identificación no invalida las conclusiones expuestas, sino que sienta las bases para futuras iteraciones del proyecto:

- **Extrapolación espacial y el Marco BAM:** En el diseño de las pseudo-ausencias, el área de calibración (la región histórica accesible o "M" en el marco BAM de la ecología de poblaciones) se restringió a los límites de Andalucía para modelizar con precisión los reductos actuales. Sin embargo, al proyectar la idoneidad térmica sobre la totalidad de la Península Ibérica, se forzó a los algoritmos a evaluar un espacio (*background*) cuyas condiciones climáticas no formaron parte

del entrenamiento. Para futuros estudios de transferibilidad peninsular, sería recomendable un diseño de pseudo-ausencias a escala macro-regional.

- **Incertidumbre en "Climas Novedosos" (Análisis MESS):** La proyección del nicho hacia el horizonte 2050 asume que las respuestas fisiológicas de la especie se mantienen constantes. No obstante, los escenarios de cambio climático suelen generar hipervolúmenes ambientales inéditos (*novel climates*) que los árboles de decisión no han evaluado durante su entrenamiento. Para cuantificar la incertidumbre matemática de esta extrapolación futura, la investigación debería complementarse mediante un análisis de Superficies de Similitud Ambiental Multivariante (MESS).
- **Sobreajuste algorítmico y afinamiento de hiperparámetros:** Como se evidenció en la volatilidad de las curvas de dependencia parcial (PDP), el algoritmo *Gradient Boosting Machine* (GBM) mostró tendencia al sobreajuste (*overfitting*) frente al *Random Forest*. En esta primera aproximación, la librería *caret* optimizó los hiperparámetros basándose en validación aleatoria. En investigaciones posteriores, resulta indispensable implementar una malla de optimización de hiperparámetros estricta (*tuneGrid*) que controle la tasa de aprendizaje (*shrinkage*) e integrando la penalización de los bloques espaciales directamente en la función de coste del modelo, evitando así que los algoritmos de *boosting* parametrizen el ruido local.

5.3 Reflexión personal y dificultades superadas

El desarrollo de este Trabajo de Fin de Grado ha supuesto un reto de gran envergadura que ha puesto a prueba y expandido los conocimientos adquiridos durante el Grado en Estadística. Un aspecto que merece especial mención es la profunda evolución conceptual del proyecto, un fiel reflejo de la naturaleza dinámica de la investigación científica.

Expectativa frente a Realidad: La propuesta inicial de este trabajo se centraba en la explotación analítica de la base de datos FAME de la Junta de Andalucía. Sin embargo, el desarrollo del proyecto se topó con un obstáculo crítico e insalvable: la imposibilidad de obtener acceso a dicho conjunto de datos. Ante este revés, en lugar de reducir el alcance de la investigación, decidí buscar alternativas en repositorios de biodiversidad en abierto. Fue en esa búsqueda donde descubrí el volumen de registros disponibles del pinsapo (*Abies pinsapo* Boiss.) y, al constatar la alarmante vulnerabilidad climática a la que está sometido, encontré la oportunidad perfecta para transfor-

mar por completo el TFG. De este modo, un problema de acceso a la información se convirtió en el motor que me impulsó a pivotar desde una tarea de gestión de bases de datos hacia un verdadero desafío de inferencia espacial, algoritmos avanzados de *Machine Learning* y simulación de escenarios de cambio climático.

- **La complejidad de la curación y el sesgo de los datos crudos:** Enfrentarse por primera vez a un repositorio masivo y heterogéneo como GBIF supuso una dificultad inicial importante. Comprender que la abundancia de datos (más de 11.000 registros brutos) era en realidad un "espejismo estadístico" lleno de observaciones con errores de imprecisión en alta montaña, obligó a diseñar un flujo de trabajo de filtrado muy estricto. La transición mental de "buscar una muestra grande" a "buscar una muestra estadísticamente limpia e independiente" ($n = 101$) supuso el primer gran aprendizaje del estudio.
- **El cambio de paradigma de la estadística clásica al Machine Learning:** Romper con la rigidez analítica de los modelos lineales aditivos tradicionales (GLM) para adentrarse en la flexibilidad no paramétrica de los algoritmos de ensamblaje (*Random Forest* y GBM) requirió un esfuerzo de asimilación conceptual. El verdadero desafío no radicó en la ejecución de los algoritmos, sino en su interpretación ecológica; entender cómo las diferentes arquitecturas matemáticas (paralela con *bagging* frente a secuencial con *boosting*) afectan a las fronteras de decisión y cómo herramientas de explicabilidad (XAI) como las curvas PDP permiten "abrir" estas cajas negras estadísticas.
- **El desafío computacional y el control de la autocorrelación:** La implementación práctica de la Validación Cruzada por Bloques Espaciales (*Spatial Block CV*) mediante código en R representó la mayor dificultad técnica del trabajo. Diseñar un experimento que desafiara activamente a los modelos dividiendo el territorio en cuadrículas independientes de 15×15 km (en lugar de recurrir al remuestreo aleatorio convencional que infla artificialmente el AUC) requirió un proceso complejo de depuración de código y optimización de recursos, aportando una valiosa competencia en computación estadística.

En conclusión, este trabajo ha permitido consolidar una visión crítica de la estadística aplicada, demostrando que el rigor en el tratamiento de los datos, la honestidad en la validación de los modelos y la capacidad para interpretar algoritmos complejos son herramientas indispensables para abordar problemas ecológicos reales y de alta relevancia social como el cambio climático.

Anexo: Código fuente en R para la Modelización Ecológica

En este anexo se detalla el script completo desarrollado en el entorno estadístico R para la ejecución metodológica de este Trabajo de Fin de Grado. El flujo de trabajo incluye la curación automatizada de los registros de biodiversidad, el filtrado espacial iterativo, el entrenamiento concurrente de los algoritmos paramétricos y de *Machine Learning*, y la proyección cartográfica bajo los distintos escenarios de cambio climático.

```
1
2 # 1. Cargar librerías necesarias
3 library(rgbf)
4 library(dplyr)
5 library(geodata)
6 library(terra)
7 library(corrplot)
8 library(usdm)
9 library(caTools)
10 library(caret)
11 library(randomForest)
12 library(pdp)
13 library(ggplot2)
14 library(gridExtra)
15 library(gbm)
16 library(pROC)
17 library(blockCV)
18 library(sf)
19 library(rnaturalearth)
20
21 # 2. Obtención del código identificador único del Pinsapo (Abies pinsapo)
22 especie <- name_backbone("Abies pinsapo")
23 id_especie <- especie$usageKey
24
25 # =====
26 # EXTRACCIÓN DE DATOS BRUTOS
27 # =====
```

```

28
29 # Definimos dónde se va a guardar nuestro archivo
30 archivo_gbif <- "datos/registros_pinsapo_gbif.rds"
31
32 if (file.exists(archivo_gbif)) {
33
34   cat("\nCargando registros de GBIF desde el disco duro local...\n")
35   df_bruto <- readRDS(archivo_gbif)
36
37 } else {
38
39   cat("\nDescargando registros de GBIF de internet por primera vez...\n")
40   # Descargamos los registros
41   datos_gbif <- occ_data(taxonKey = id_especie,
42                           country = "ES",
43                           hasCoordinate = TRUE,
44                           limit = 20000)
45
46   # Extraemos el dataframe
47   df_bruto <- datos_gbif$data
48
49   # Lo guardamos
50   saveRDS(df_bruto, archivo_gbif)
51   cat("Archivo guardado con éxito en:", archivo_gbif, "\n")
52 }
53
54 # Registros obtenidos:
55 nrow(df_bruto)
56
57 # =====
58 # FASE 1: ANÁLISIS DEL DISEÑO Y CALIDAD DE LA BASE DE DATOS (METADATOS)
59 # =====
60
61 analisis_metadatos <- df_bruto %>%
62   # Agrupamos por la naturaleza del registro (Herbario vs. Observación humana)
63   group_by(basisOfRecord) %>%
64
65   # Calculamos métricas estadísticas de calidad para cada grupo
66   summarise(
67     Volumen_Total = n(),
68     Falta_Año_pct = round(sum(is.na(year)) / n() * 100, 1),
69     Incertidumbre_Media_m = round(mean(coordinateUncertaintyInMeters,
70                                         na.rm = TRUE), 1),
71     Año_Mas_Antiguo = min(year, na.rm = TRUE),
72     Año_Mas_Reciente = max(year, na.rm = TRUE)
73   ) %>%
74   arrange(desc(Volumen_Total)) # Ordenamos de mayor a menor volumen
75
76 # Imprimimos la tabla comparativa en la consola
77 print(analisis_metadatos)
78
79 # =====
80 # FASE 2: INGENIERÍA DE DATOS Y LIMPIEZA ESTADÍSTICA (PREPARACIÓN PARA MODELO)
81 # =====
82
83 df_limpio <- df_bruto %>%
84   # Seleccionamos solo las columnas útiles para el modelo y el análisis
85   select(scientificName, decimalLongitude, decimalLatitude, year,

```

```

86     basisOfRecord, institutionCode, coordinateUncertaintyInMeters) %>%
87
88     # Eliminamos registros históricos que no tengan año de muestreo
89     filter(!is.na(year)) %>%
90
91     # CONTROL DE CALIDAD ESPACIAL:
92     # Nos quedamos estrictamente con datos de altísima precisión (<= 500m)
93     filter(coordinateUncertaintyInMeters <= 500) %>%
94
95     # Filtramos la naturaleza del dato (evitamos material de jardinería...)
96     filter(basisOfRecord %in% c("HUMAN_OBSERVATION", "PRESERVED_SPECIMEN"))
97
98     # Registros obtenidos tras filtros de incertidumbre:
99     nrow(df_limpio)
100
101     # =====
102     # AUDITORÍA DE LA MUESTRA FINAL
103     # =====
104
105     composicion_final <- df_limpio %>%
106     group_by(basisOfRecord) %>%
107     summarise(
108         Total = n(),
109         Porcentaje = round((n() / nrow(df_limpio)) * 100, 1)
110     ) %>%
111     arrange(desc(Total))
112
113     # Tabla
114     print(composicion_final)
115
116     # =====
117     # FASE 3: CRUCE DE COORDENADAS (GBIF) CON VARIABLES AMBIENTALES (WORLDCLIM)
118     # =====
119
120     # 1. DESCARGA DEL CLIMA DE ESPAÑA
121     ruta_local = "datos"
122     clima_global <- worldclim_country(country = "Spain",
123                                     var = "bio",
124                                     res = 0.5,
125                                     path = ruta_local)
126     names(clima_global) <- paste0("BIO", 1:19)
127
128     # --- Variables de Temperatura (En °C) ---
129     # BIO1 : Temperatura Media Anual
130     # BIO2 : Oscilación Diurna Media (Media mensual de (Temp máx - Temp mín))
131     # BIO3 : Isothermalidad (BIO2 / BIO7 * 100) -> [Estabilidad térmica día
132     #                                           /noche vs año]
133     # BIO4 : Estacionalidad de la Temperatura (Desviación estándar * 100)
134     # BIO5 : Temperatura Máxima del Mes Más Cálido
135     # BIO6 : Temperatura Mínima del Mes Más Frío
136     # BIO7 : Oscilación Térmica Anual (BIO5 - BIO6)
137     # BIO8 : Temperatura Media del Trimestre Más Húmedo
138     # BIO9 : Temperatura Media del Trimestre Más Seco
139     # BIO10 : Temperatura Media del Trimestre Más Cálido
140     # BIO11 : Temperatura Media del Trimestre Más Frío
141
142     # --- Variables de Precipitación (En milímetros - mm) ---
143     # BIO12 : Precipitación Anual

```

```

144 # BIO13 : Precipitación del Mes Más Húmedo
145 # BIO14 : Precipitación del Mes Más Seco
146 # BIO15 : Estacionalidad de la Precipitación (Coeficiente de Variación)
147 # [Ritmo de lluvias]
148 # BIO16 : Precipitación del Trimestre Más Húmedo
149 # BIO17 : Precipitación del Trimestre Más Seco
150 # BIO18 : Precipitación del Trimestre Más Cálido
151 # BIO19 : Precipitación del Trimestre Más Frío
152
153 # 2. DESCARGA DE ELEVACIÓN (ALTITUD)
154 elev_global <- elevation_30s(country = "Spain", path = ruta_local)
155 names(elev_global) <- "elevacion"
156
157 # Aseguramos que coincidan perfectamente en resolución y extensión
158 elev_global <- resample(elev_global, clima_global)
159 clima_global <- c(clima_global, elev_global)
160
161 # 3. CONVERSIÓN ESPACIAL
162 # Convertimos nuestro dataframe limpio en "puntos espaciales"
163 puntos_pinsapo <- vect(df_limpio,
164                        geom = c("decimalLongitude", "decimalLatitude"),
165                        crs = "EPSG:4326") # Coordenadas GPS estándar
166
167 # 4. CRUCE (EXTRACCIÓN)
168 # Extraemos el clima exacto de cada una de las 467 coordenadas.
169 clima_pinsapo <- terra::extract(clima_global, puntos_pinsapo)
170
171 # Unimos los datos climáticos a nuestro dataframe original
172 df_modelo <- cbind(df_limpio, clima_pinsapo[, -1])
173 colnames(df_modelo)
174
175 # Comprobación rápida de que la extracción ha funcionado
176 head(df_modelo$BIO5)
177
178 # =====
179 # FASE 4: EXTRACCIÓN TOTAL Y ANÁLISIS DE MULTICOLINEALIDAD (EDA)
180 # =====
181
182 # 1. Limpieza de la matriz
183 # La función terra::extract() añade una primera columna llamada "ID"
184 # que no es clima. La quitamos.
185 clima_vars <- clima_pinsapo[, -1]
186
187 # 2. Calculamos la Matriz de Correlación de Pearson
188 # Usamos use="complete.obs" por si se nos ha colado algún NA en el mar o bordes
189 matriz_correlacion <- cor(clima_vars, use = "complete.obs")
190
191 # 3. Visualización de la Matriz
192 corrplot(matriz_correlacion,
193          method = "color",
194          type = "upper",
195          tl.col = "black",
196          tl.srt = 45,
197          addCoef.col = "black",
198          number.cex = 0.5,
199          diag = FALSE,
200          title = "Matriz de Correlación de Pearson - Variables Bioclimáticas",
201          mar = c(0,0,1,0))

```

```

202
203 # =====
204 # FASE 5: VIF AUTOMATIZADO SOBRE EL NICHOS REALIZADO (FILTRADO)
205 # =====
206
207 # 1. Recortamos Andalucía temporalmente con las 19 variables completas
208 limites_sur <- ext(-8.5, -1.5, 35.5, 39.0)
209 clima_sur_completo <- crop(clima_global, limites_sur)
210
211 # 2. Filtro Espacial (Thinning): Máximo 1 punto por píxel de 1km
212 celdas_ocupadas <- terra::extract(clima_sur_completo[[1]], puntos_pinsapo,
213                                   cells = TRUE)$cell
214 celdas_unicas <- unique(na.omit(celdas_ocupadas))
215 coords_thin <- xyFromCell(clima_sur_completo[[1]], celdas_unicas)
216 puntos_presencia_limpios <- vect(coords_thin, crs = crs(clima_sur_completo))
217
218 # 3. Extraemos el clima EXACTO de los 101 pinsapos limpios
219 clima_pinsapos_limpios <- terra::extract(clima_sur_completo,
220                                           puntos_presencia_limpios)[, -1]
221 df_clima_pinsapo <- na.omit(as.data.frame(clima_pinsapos_limpios))
222
223 # 4. Cálculo del VIF dinámico
224 # Pasamos de th = 10 a th = 5 para máximo rigor ecológico
225 seleccion_vif <- vifstep(df_clima_pinsapo, th = 5)
226 clima_final_pinsapo <- exclude(df_clima_pinsapo, seleccion_vif)
227
228 # 5. Extraemos los nombres ganadores a la variable oro
229 variables_oro <- colnames(clima_final_pinsapo)
230
231 ## VARIABLES SELECCIONADAS AUTOMÁTICAMENTE POR EL VIF
232 print(variables_oro)
233
234
235 # =====
236 # FASE 6: PREPARACIÓN ESPACIAL Y RATIO 1:1
237 # =====
238
239 # 1. Recortamos el mapa oficial usando solo las variables de oro
240 clima_sur <- subset(clima_sur_completo, variables_oro)
241
242 # ---- FIX PARA ELIMINAR EL MAR -----
243 # Descargamos el polígono de España y nos quedamos solo con Andalucía
244 fronteras_espana <- gadm(country = "ESP", level = 1, path = ruta_local)
245 andalucia <- fronteras_espana[fronteras_espana$NAME_1 == "Andalucía", ]
246
247 # Enmascaramos el raster climático (todo lo que caiga fuera de Andalucía o
248 # en el mar será NA)
249 clima_sur <- mask(clima_sur, andalucia)
250 # -----
251
252 # 2. Pseudo-ausencias con Buffer de Exclusión y Ratio 1:1
253 buffer_presencias <- buffer(puntos_presencia_limpios, width = 2000)
254 clima_para_ausencias <- mask(clima_sur, buffer_presencias, inverse = TRUE)
255
256 num_presencias <- nrow(coords_thin)
257
258 set.seed(123)
259 puntos_ausencia <- spatSample(clima_para_ausencias[[1]],

```

```

260         size = num_presencias,
261         method = "random",
262         na.rm = TRUE,
263         as.points = TRUE)
264
265 ## BALANCE DE CLASES
266 num_presencias
267
268 # 3. Construcción del Dataset Maestro Limpio
269 clima_ausencias <- terra::extract(clima_sur, puntos_ausencia)[, variables_oro]
270 clima_ausencias$Presencia <- 0
271
272 clima_presencias <- df_clima_pinsapo[, variables_oro]
273 clima_presencias$Presencia <- 1
274
275 datos_modelo <- rbind(clima_presencias, clima_ausencias)
276 datos_modelo <- na.omit(datos_modelo)
277
278 # =====
279 # FASE 7: ENTRENAMIENTO RANDOM FOREST CON VALIDACIÓN CRUZADA (K-FOLD CV)
280 # =====
281
282 # 1. Preparamos los datos
283 datos_cv <- datos_modelo
284 datos_cv$Presencia <- factor(datos_cv$Presencia,
285                             levels = c(0, 1),
286                             labels = c("Ausencia", "Presencia"))
287
288 # 2. Configurar la Validación Cruzada (5 exámenes distintos)
289 control_cv <- trainControl(method = "cv",
290                             number = 5,
291                             summaryFunction = twoClassSummary,
292                             classProbs = TRUE,
293                             savePredictions = "final")
294
295 # 3. Entrenamiento
296 set.seed(123)
297 modelo_rf_cv <- train(Presencia ~ .,
298                       data = datos_cv,
299                       method = "rf",
300                       ntree = 500,
301                       importance = TRUE,
302                       trControl = control_cv,
303                       metric = "ROC")
304
305 # 4. Ver la nota final real
306 print(modelo_rf_cv)
307
308 # 5. Resultados
309 print(modelo_rf_cv$finalModel$confusion)
310 confusionMatrix(modelo_rf_cv)
311
312 # 6. Cálculo del TSS
313 mejor_fila_rf <- which.max(modelo_rf_cv$results$ROC)
314 sens_rf <- modelo_rf_cv$results$Sens[mejor_fila_rf]
315 spec_rf <- modelo_rf_cv$results$Spec[mejor_fila_rf]
316
317 tss_rf <- sens_rf + spec_rf - 1

```

```

318 round(tss_rf, 3)
319
320 ## GRAFICOS PDP (Partial Dependence Plots)
321
322 # 1. Generar las curvas individuales guardándolas en variables (p1, p2, p3)
323 p1 <- partial(modelo_rf_cv, pred.var = "BI03", prob = TRUE, plot = TRUE,
324               which.class = 2, plot.engine = "ggplot2", ylab = "Probabilidad",
325               main = "BI03 (Isotermalidad)")
326
327 p2 <- partial(modelo_rf_cv, pred.var = "BI015", prob = TRUE, plot = TRUE,
328               which.class = 2, plot.engine = "ggplot2", ylab = "Probabilidad",
329               main = "BI015 (Estacionalidad)")
330
331 p3 <- partial(modelo_rf_cv, pred.var = "BI08", prob = TRUE, plot = TRUE,
332               which.class = 2, plot.engine = "ggplot2", ylab = "Probabilidad",
333               main = "BI08 (Temp. Húmedo)")
334
335 # 2. Mostrar los tres gráficos juntos
336 grid.arrange(p1, p2, p3, ncol = 3)
337
338 # =====
339 # FASE 8: ENTRENAMIENTO GLM CON VALIDACIÓN CRUZADA (K-FOLD CV)
340 # =====
341
342 set.seed(123)
343
344 modelo_glm_cv <- train(Presencia ~ .,
345                        data = datos_cv,
346                        method = "glm",
347                        family = "binomial",
348                        trControl = control_cv,
349                        metric = "ROC")
350
351 # 1. Ver la nota final del GLM
352 print(modelo_glm_cv)
353
354 # 2. Ver la matriz de confusión promedio
355 confusionMatrix(modelo_glm_cv)
356
357 # 3. Comprobar la Devianza en consola
358 summary(modelo_glm_cv$finalModel)
359
360 # 4. Cálculo del TSS
361 mejor_fila_glm <- which.max(modelo_glm_cv$results$ROC)
362 sens_glm <- modelo_glm_cv$results$Sens[mejor_fila_glm]
363 spec_glm <- modelo_glm_cv$results$Spec[mejor_fila_glm]
364
365 tss_glm <- sens_glm + spec_glm - 1
366 round(tss_glm, 3)
367
368 # 5. Generar el gráfico con los 4 diagnósticos
369 par(mfrow = c(2, 2))
370 plot(modelo_glm_cv$finalModel)
371 par(mfrow = c(1, 1))
372
373 # =====
374 # FASE 9: ENTRENAMIENTO GRADIENT BOOSTING (GBM) CON K-FOLD CV
375 # =====

```

```

376
377 # Usamos la misma semilla para que los exámenes sean idénticos al RF y GLM
378 set.seed(123)
379
380 modelo_gbm_cv <- train(Presencia ~ .,
381                        data = datos_cv,
382                        method = "gbm",
383                        trControl = control_cv,
384                        metric = "ROC",
385                        verbose = FALSE)
386
387 # 1. Ver la nota final del GBM
388 print(modelo_gbm_cv)
389
390 # 2. Ver la matriz de confusión promedio
391 confusionMatrix(modelo_gbm_cv)
392
393 # 3. Cálculo del TSS
394 mejor_fila_gbm <- which.max(modelo_gbm_cv$results$ROC)
395 sens_gbm <- modelo_gbm_cv$results$Sens[mejor_fila_gbm]
396 spec_gbm <- modelo_gbm_cv$results$Spec[mejor_fila_gbm]
397
398 tss_gbm <- sens_gbm + spec_gbm - 1
399 round(tss_gbm, 3)
400
401 ## GRAFICOS PDP
402
403 # 1. Generar las curvas individuales guardándolas en variables (p1, p2, p3)
404 p1_gbm <- partial(modelo_gbm_cv, pred.var = "BI03", prob = TRUE, plot = TRUE,
405                  which.class = 2, plot.engine = "ggplot2",
406                  ylab = "Probabilidad", main = "BI03 (Isotermalidad)")
407
408 p2_gbm <- partial(modelo_gbm_cv, pred.var = "BI015", prob = TRUE, plot = TRUE,
409                  which.class = 2, plot.engine = "ggplot2",
410                  ylab = "Probabilidad", main = "BI015 (Estacionalidad)")
411
412 p3_gbm <- partial(modelo_gbm_cv, pred.var = "BI08", prob = TRUE, plot = TRUE,
413                  which.class = 2, plot.engine = "ggplot2",
414                  ylab = "Probabilidad", main = "BI08 (Temp. Húmedo)")
415
416 # 2. Mostrar los tres gráficos juntos
417 grid.arrange(p1_gbm, p2_gbm, p3_gbm, ncol = 3)
418
419
420 # =====
421 # FASE 10: VISUALIZACIÓN COMPARATIVA (RF vs GLM vs GBM)
422 # =====
423
424 # 1. CÁLCULO DE CURVAS ROC
425 roc_rf <- roc(modelo_rf_cv$pred$obs, modelo_rf_cv$pred$Presencia,
426               quiet = TRUE)
427 roc_glm <- roc(modelo_glm_cv$pred$obs, modelo_glm_cv$pred$Presencia,
428               quiet = TRUE)
429 roc_gbm <- roc(modelo_gbm_cv$pred$obs, modelo_gbm_cv$pred$Presencia,
430               quiet = TRUE)
431
432 # Usamos max() para coger el mejor resultado
433 auc_rf <- auc(roc_rf)

```



```

434 auc_glm <- auc(roc_glm)
435 auc_gbm <- auc(roc_gbm)
436
437 # 2. COMPARACIÓN DE CURVAS ROC (3 MODELOS)
438 plot(roc_rf, col = "forestgreen", lwd = 2,
439      main = "Comparativa de Modelos (5-fold CV)")
440 plot(roc_gbm, col = "darkorange", lwd = 2, add = TRUE)
441 plot(roc_glm, col = "steelblue", lwd = 2, add = TRUE)
442
443 # 2. Leyenda
444 legend("bottomright",
445       legend = c(
446         paste0("GBM (AUC: ", round(auc_gbm,3), ")"),
447         paste0("GLM (AUC: ", round(auc_glm,3), ")"),
448         paste0("Random Forest (AUC: ", round(auc_rf,3), ")")
449       ),
450       col = c("darkorange", "steelblue", "forestgreen"),
451       lwd = 2,
452       cex = 0.8)
453
454 # 3. IMPORTANCIA DE VARIABLES (Basado en RF)
455 # Extraemos la importancia unificada usando caret
456 importancia_rf <- varImp(modelo_rf_cv, scale = FALSE)
457
458 valores_rf <- importancia_rf$importance[, 1]
459 nombres_rf <- rownames(importancia_rf$importance)
460
461 datos_barras_rf <- setNames(valores_rf, nombres_rf)
462 datos_barras_rf <- sort(datos_barras_rf, decreasing = FALSE)
463
464 par(mar = c(5, 5, 4, 2))
465 barplot(datos_barras_rf,
466       horiz = TRUE,
467       las = 1,
468       col = "forestgreen",
469       border = "black",
470       main = "Importancia de Variables (Random Forest)",
471       xlab = "Nivel de Importancia")
472
473 # 4. IMPORTANCIA DE VARIABLES (Basado en GLM)
474 importancia_glm <- varImp(modelo_glm_cv, scale = FALSE)
475
476 valores_glm <- importancia_glm$importance[, 1]
477 nombres_glm <- rownames(importancia_glm$importance)
478
479 datos_barras_glm <- setNames(valores_glm, nombres_glm)
480 datos_barras_glm <- sort(datos_barras_glm, decreasing = FALSE)
481
482 par(mar = c(5, 5, 4, 2))
483 barplot(datos_barras_glm,
484       horiz = TRUE,
485       las = 1,
486       col = "steelblue",
487       border = "black",
488       main = "Importancia de Variables (Regresión Logística - GLM)",
489       xlab = "Valor Z absoluto (Fuerza de la variable)")
490
491 # 5. IMPORTANCIA DE VARIABLES (Basado en GBM)

```

```

492 importancia_gbm <- varImp(modelo_gbm_cv, scale = FALSE)
493
494 valores_gbm <- importancia_gbm$importance[, 1]
495 nombres_gbm <- rownames(importancia_gbm$importance)
496
497 datos_barras_gbm <- setNames(valores_gbm, nombres_gbm)
498 datos_barras_gbm <- sort(datos_barras_gbm, decreasing = FALSE)
499
500 par(mar = c(5, 5, 4, 2))
501 barplot(datos_barras_gbm,
502         horiz = TRUE,
503         las = 1,
504         col = "darkorange",
505         border = "black",
506         main = "Importancia de Variables (Gradient Boosting - GBM)",
507         xlab = "Nivel de Importancia")
508
509 par(mar = c(5, 4, 4, 2) + 0.1)
510
511 # =====
512 # FASE 11: PROYECCIÓN ESPACIAL DEL NICHOS ECOLÓGICO (MAPA FINAL GLM)
513 # =====
514
515 # Con caret, type = "prob" devuelve 2 valores (probabilidad de Ausencia
516 # y de Presencia). Con index = 2 le decimos que mapee
517 # la probabilidad de PRESENCIA.
518 mapa_prob_glm <- predict(clima_sur, modelo_glm_cv, type = "prob", index = 2,
519                          na.rm = TRUE)
520
521 # 1. DISEÑO VISUAL
522 paleta_colores <- colorRampPalette(c("#e0e0e0", "#abdda4", "#ffffbf",
523                                     "#fdae61", "#d7191c"))(100)
524
525 # 2. DIBUJAMOS EL MAPA BASE
526 plot(mapa_prob_glm,
527      main = "Hábitat Potencial de Abies pinsapo (GLM)",
528      col = paleta_colores,
529      plg = list(title = "Idoneidad\n(0 a 1)"))
530
531 # 3. SUPERPONEMOS LA REALIDAD
532 plot(puntos_pinsapo, add = TRUE, col = "black", pch = 16, cex = 0.4)
533
534 # =====
535 # FASE 12: PROYECCIÓN ESPACIAL DEL NICHOS ECOLÓGICO (MAPA FINAL RANDOM FOREST)
536 # =====
537
538 # Proyección idéntica a la del GLM pero con el modelo RF
539 mapa_prob_rf <- predict(clima_sur, modelo_rf_cv, type = "prob", index = 2,
540                        na.rm = TRUE)
541
542 # 1. DIBUJAMOS EL MAPA BASE
543 plot(mapa_prob_rf,
544      main = "Hábitat Potencial de Abies pinsapo (Random Forest)",
545      col = paleta_colores,
546      plg = list(title = "Idoneidad\n(0 a 1)"))
547
548 # 2. SUPERPONEMOS LA REALIDAD
549 plot(puntos_pinsapo, add = TRUE, col = "black", pch = 16, cex = 0.4)

```

```

550
551 # =====
552 # FASE 13: PROYECCIÓN ESPACIAL DEL NICHÓ ECOLÓGICO (MAPA FINAL GBM)
553 # =====
554
555 # Proyección idéntica a la del GLM pero con el modelo RF
556 mapa_prob_gbm <- predict(clima_sur, modelo_gbm_cv, type = "prob", index = 2,
557                          na.rm = TRUE)
558
559 # 1. DIBUJAMOS EL MAPA BASE
560 plot(mapa_prob_gbm,
561      main = "Hábitat Potencial de Abies pinsapo (GBM)",
562      col = paleta_colores,
563      plg = list(title = "Idoneidad\n(0 a 1)"))
564
565 # 2. SUPERPONEMOS LA REALIDAD
566 plot(puntos_pinsapo, add = TRUE, col = "black", pch = 16, cex = 0.4)
567
568 # =====
569 # FASE 14: Spatial Block Cross-Validation
570 # =====
571
572 # RECUPERAR COORDENADAS Y UNIRLAS A LOS DATOS
573 # Extraemos las coordenadas (lon, lat) de los SpatVector
574 coords_presencia <- crds(puntos_presencia_limpios)
575 coords_ausencia <- crds(puntos_ausencia)
576
577 # Las juntamos una encima de otra (primero 101 pres, luego 101 aus)
578 todas_las_coords <- rbind(coords_presencia, coords_ausencia)
579 coords_df <- as.data.frame(todas_las_coords)
580 colnames(coords_df) <- c("lon", "lat")
581
582 # Pegamos las coordenadas
583 datos_completos <- cbind(coords_df, datos_cv)
584
585 # 1. CONVERTIR DATOS A FORMATO ESPACIAL
586 datos_sf <- st_as_sf(datos_completos, coords = c("lon", "lat"), crs = 4326)
587
588 # 2. GENERAR LOS BLOQUES ESPACIALES (Cuadrículas de 15 km)
589 set.seed(123)
590 bloques <- cv_spatial(x = datos_sf,
591                       column = "Presencia",
592                       k = 5,
593                       size = 15000,
594                       iteration = 50)
595
596 # 1. Extraer SOLO los índices de entrenamiento (train) de los bloques
597 # espaciales
598 indices_espaciales <- lapply(bloques$folds_list, function(x) x[[1]])
599 names(indices_espaciales) <- paste0("Fold", 1:5)
600
601 # 2. Re-crear el control espacial con la lista limpia
602 control_espacial <- trainControl(method = "cv",
603                                  index = indices_espaciales,
604                                  classProbs = TRUE,
605                                  summaryFunction = twoClassSummary)
606
607 # 3. Re-entrenar los modelos

```

```

608 formula_dinamica <- as.formula(paste("Presencia ~", paste(variables_oro,
609                                                                 collapse = " + ")))
610 modelo_glm_esp <- train(formula_dinamica,
611                          data = datos_completos,
612                          method = "glm",
613                          family = "binomial",
614                          metric = "ROC",
615                          trControl = control_espacial)
616
617 modelo_rf_esp <- train(formula_dinamica,
618                       data = datos_completos,
619                       method = "rf",
620                       metric = "ROC",
621                       trControl = control_espacial)
622
623 modelo_gbm_esp <- train(formula_dinamica,
624                        data = datos_completos,
625                        method = "gbm",
626                        metric = "ROC",
627                        trControl = control_espacial,
628                        verbose = FALSE)
629
630 # 4. Ver los resultados
631
632 modelo_glm_esp$results[which.max(modelo_glm_esp$results$ROC), ]
633 modelo_rf_esp$results[which.max(modelo_rf_esp$results$ROC), ]
634 modelo_gbm_esp$results[which.max(modelo_gbm_esp$results$ROC), ]
635
636 ## MAPA DE LOS BLOQUES ESPACIALES
637
638 # 1. Descargar el mapa base de España
639 espana <- ne_countries(scale = "medium", country = "Spain", returnclass = "sf")
640
641 # 2. Asignamos el número de bloque directamente a cada punto
642 datos_sf$Fold <- as.factor(bloques$fold_ids)
643
644 # 3. Creamos el mapa
645 mapa_ev <- ggplot() +
646   # Fondo de Andalucía
647   geom_sf(data = espana, fill = "gray98", color = "gray70") +
648
649   # Dibujamos los puntos: Color = Pliegue (Fold), Forma = Presencia/Ausencia
650   geom_sf(data = datos_sf, aes(color = Fold, shape = Presencia), size = 2.5,
651         alpha = 0.9) +
652
653   # Zoom a Andalucía
654   coord_sf(xlim = c(-8.5, -1.5), ylim = c(35.5, 39.0)) +
655
656   # Colores
657   scale_color_brewer(palette = "Set1", name = "Bloque Espacial") +
658   scale_shape_manual(values = c("Ausencia" = 4, "Presencia" = 16)) +
659
660   theme_minimal() +
661   labs(title = "Validación Cruzada por Bloques Espaciales (Spatial CV)",
662        subtitle = "Agrupación geográfica de las muestras para
663          evitar autocorrelación",
664        x = "Longitud", y = "Latitud") +
665   theme(legend.position = "right",

```

```

666     panel.background = element_rect(fill = "#eef7fa", color = NA),
667     panel.grid.major = element_line(color = "white"))
668
669 # Mostrar el mapa
670 print(mapa_ev)
671
672 # =====
673 # FASE 15: EXTRAPOLACIÓN PENINSULAR DEL NICHÓ (Refugios climáticos)
674 # =====
675
676 # 1. DESCARGAR Y FUSIONAR ESPAÑA Y PORTUGAL
677
678 frontera_esp <- gadm(country = "ESP", level = 0, path = ruta_local)
679 frontera_prt <- gadm(country = "PRT", level = 0, path = ruta_local)
680
681 # Unimos los países para el mapa principal
682 macro_region <- rbind(frontera_esp, frontera_prt)
683
684 # Creamos una máscara de corte (extent) centrada en Península
685 limites_mapa_principal <- ext(-10, 5, 35.8, 44)
686
687 # 2. Hacemos un corte para reducir el tamaño a nuestra zona.
688 clima_actual_corte <- crop(clima_global, limites_mapa_principal)
689
690 # 3. Enmascaramos con los países (para quitar el mar)
691 clima_actual_macro <- mask(clima_actual_corte, macro_region)
692
693 # 4. PREDICCIONES
694 mapa_actual_rf <- predict(subset(clima_actual_macro, variables_oro),
695                           modelo_rf_esp, type = "prob", index = 2,
696                           na.rm = TRUE)
697
698
699 # Mapa: Estado Actual
700 plot(mapa_actual_rf, main = "Extrapolación del Hábitat Potencial",
701      col = paleta_colores,
702      plg = list(title = "Idoneidad", x = "right"),
703      axes = FALSE)
704
705 ### MAPA PRESENCIAS GBIF
706
707 par(mar = c(1, 1, 3, 1))
708
709 plot(0, 0, type = "n",
710      xlim = c(xmin(limites_mapa_principal), xmax(limites_mapa_principal)),
711      ylim = c(ymin(limites_mapa_principal), ymax(limites_mapa_principal)),
712      axes = FALSE,
713      xlab = "", ylab = "",
714      main = "Distribución Observada (Registros de Muestreo)",
715      asp = 1.3)
716
717 plot(macro_region,
718      col = "white",
719      border = "gray88",
720      axes = FALSE,
721      add = TRUE)
722
723 coords_puntos <- crds(puntos_pinsapo)

```

```

724 points(coords_puntos[,1], coords_puntos[,2],
725         col = "black",
726         pch = 16,
727         cex = 0.1)
728
729 par(mar = c(5, 4, 4, 2) + 0.1)
730
731 # =====
732 # FASE 16: TRANSFERIBILIDAD ESPACIAL (MARRUECOS Y LA CORDILLERA DEL RIF)
733 # =====
734
735 # Recuperamos el polígono de España
736
737 clima_nacional <- subset(clima_global, variables_oro)
738
739 # 1. Descargamos las fronteras y ajustamos al Rif
740 fronteras_marruecos <- gadm(country = "MAR", level = 0, path = ruta_local)
741 clima_marruecos_norte <- crop(clima_nacional, ext(-6.5, -3.0, 34.0, 36.0))
742 clima_marruecos_norte <- mask(clima_marruecos_norte, fronteras_marruecos)
743
744 # 2. PREDECIR usando el modelo RF espacial
745 mapa_marruecos_rf <- predict(clima_marruecos_norte, modelo_rf_esp,
746                             type = "prob", index = 2, na.rm = TRUE)
747
748 # 3. DIBUJAMOS EL MAPA
749 par(mar = c(3, 3, 4, 6))
750
751 plot(mapa_marruecos_rf,
752      main = "Transferibilidad: Nicho Climático en Marruecos",
753      col = paleta_colores,
754      plg = list(title = "Idoneidad\n(0 a 1)", x = "right"),
755      axes = TRUE)
756
757 par(mar = c(5, 4, 4, 2) + 0.1)
758
759 # =====
760 # FASE 17: PROYECCIÓN CAMBIO CLIMÁTICO 2050 (MÁXIMA RESOLUCIÓN 0.5)
761 # =====
762
763 ## DESCARGA DE LOS ESCENARIOS CLIMÁTICOS
764 # ESCENARIO MODERADO (SSP2-4.5)
765 # clima_245_global <- cmip6_world(model = "MPI-ESM1-2-HR", ssp = "245",
766 #                                time = "2041-2060", var = "bioc",
767 #                                res = 0.5, path = ruta_local)
768
769 # ESCENARIO PESIMISTA (SSP5-8.5)
770 # clima_585_global <- cmip6_world(model = "MPI-ESM1-2-HR", ssp = "585",
771 #                                time = "2041-2060", var = "bioc",
772 #                                res = 0.5, path = ruta_local)
773
774 # Definimos las rutas a los archivos
775 ruta_245 <- "datos/cmip6/30s/MPI-ESM1-2-HR/ssp245/
776            wc2.1_30s_bioc_MPI-ESM1-2-HR_ssp245_2041-2060.tif"
777 ruta_585 <- "datos/cmip6/30s/MPI-ESM1-2-HR/ssp585/
778            wc2.1_30s_bioc_MPI-ESM1-2-HR_ssp585_2041-2060.tif"
779
780 # Usamos rast() para cargar los archivos
781 clima_245_global <- rast(ruta_245)

```

```

782 clima_585_global <- rast(ruta_585)
783
784 # Nombramos las capas como lo hace WorldClim (BI01, BI02...)
785 names(clima_245_global) <- paste0("BI0", 1:19)
786 names(clima_585_global) <- paste0("BI0", 1:19)
787
788 # 1. Recorte y Enmascarado
789 clima_245_sur <- mask(crop(clima_245_global, limites_sur), andalucia)
790 clima_585_sur <- mask(crop(clima_585_global, limites_sur), andalucia)
791
792 # 2. Predicción con Random Forest
793 mapa_245_rf <- predict(subset(clima_245_sur, variables_oro), modelo_rf_esp,
794                       type = "prob", index = 2, na.rm = TRUE)
795
796 mapa_585_rf <- predict(subset(clima_585_sur, variables_oro), modelo_rf_esp,
797                       type = "prob", index = 2, na.rm = TRUE)
798
799 # =====
800 # FASE 18: PROYECCIÓN A NIVEL DE LA PENÍNSULA IBÉRICA (BIOGEOGRAFÍA REAL)
801 # =====
802
803 frontera_mar <- gadm(country = "MAR", level = 0, path = ruta_local)
804 macro_region_2 <- rbind(frontera_esp, frontera_prt, frontera_mar)
805 limites_mapa_cambio <- ext(-10, 5, 34.0, 44)
806
807 # 1. Hacemos un corte
808 clima_245_corte <- crop(clima_245_global, limites_mapa_cambio)
809 clima_585_corte <- crop(clima_585_global, limites_mapa_cambio)
810
811 # 2. Enmascaramos con los países
812 clima_245_macro <- mask(clima_245_corte, macro_region_2)
813 clima_585_macro <- mask(clima_585_corte, macro_region_2)
814
815 # 3. PREDICCIONES
816 mapa_245_mac_rf <- predict(subset(clima_245_macro, variables_oro),
817                           modelo_rf_esp, type = "prob", index = 2,
818                           na.rm = TRUE)
819 mapa_585_mac_rf <- predict(subset(clima_585_macro, variables_oro),
820                           modelo_rf_esp, type = "prob", index = 2,
821                           na.rm = TRUE)
822
823 # DIBUJADO DE MAPAS LIMPIO
824
825 par(mfrow = c(1, 1))
826
827 # Mapa 1: 2050 Moderado
828 plot(mapa_245_mac_rf, main = "2050 Moderado (SSP2-4.5)", col = paleta_colores,
829      axes = FALSE, range = c(0, 1))
830
831 # Mapa 2: 2050 Pesimista
832 plot(mapa_585_mac_rf, main = "2050 Pesimista (SSP5-8.5)", col = paleta_colores,
833      axes = FALSE, range = c(0, 1))
834
835 # =====
836 # COMPARATIVA DE OVERFITTING (RF, GBM y GLM)
837 # =====
838
839 # 1. Extraemos todas las notas (AUC) de los exámenes

```

```

840 # Random Forest
841 auc_rf_ran <- modelo_rf_cv$resample$ROC
842 auc_rf_esp <- modelo_rf_esp$resample$ROC
843 # GBM
844 auc_gbm_ran <- modelo_gbm_cv$resample$ROC
845 auc_gbm_esp <- modelo_gbm_esp$resample$ROC
846 # GLM
847 auc_glm_ran <- modelo_glm_cv$resample$ROC
848 auc_glm_esp <- modelo_glm_esp$resample$ROC
849
850 # 2. Construimos la tabla completa
851 datos_multi_overfitting <- data.frame(
852   AUC = c(auc_rf_ran, auc_rf_esp, auc_gbm_ran, auc_gbm_esp, auc_glm_ran,
853           auc_glm_esp),
854
855   Modelo = factor(rep(c("Random Forest", "Gradient Boosting (GBM)",
856                         "Regresión Logística (GLM)"), each = 10),
857                  levels = c("Random Forest", "Gradient Boosting (GBM)",
858                             "Regresión Logística (GLM)")),
859
860   Validacion = rep(rep(c("1. Aleatoria", "2. Espacial"), each = 5), 3)
861 )
862
863 grafico_multi <- ggplot(datos_multi_overfitting, aes(x = Validacion,
864                                                     y = AUC,
865                                                     fill = Validacion)) +
866   geom_boxplot(alpha = 0.6, width = 0.5, outlier.shape = NA,
867               color = "darkgrey") +
868   geom_jitter(width = 0.1, size = 3, color = "#2c3e50", alpha = 0.8) +
869
870   # Separamos en 3 paneles
871   facet_wrap(~Modelo) +
872
873   scale_fill_manual(values = c("1. Aleatoria" = "#e74c3c",
874                                "2. Espacial" = "#2ecc71")) +
875   theme_bw() + # Fondo blanco con bordes limpios
876   labs(title = "Impacto de la Autocorrelación Espacial por Algoritmo",
877        subtitle = "Comparativa del AUC (5-fold) entre validación Aleatoria
878                  y Bloques Espaciales de 15km",
879        y = "Rendimiento (AUC)",
880        x = "") +
881   theme(legend.position = "bottom",
882         legend.title = element_blank(),
883         plot.title = element_text(face = "bold", size = 14),
884         strip.text = element_text(face = "bold", size = 11, color = "white"),
885         strip.background = element_rect(fill = "#2c3e50"),
886         axis.text.x = element_blank(),
887         axis.ticks.x = element_blank())
888
889 # Mostrar el gráfico
890 print(grafico_multi)

```


Bibliografía

- [1] ALBA-SÁNCHEZ, F., LÓPEZ-SÁEZ, J. A., BENITO-GARZÓN, M., AND LINARES, J. C. Past and present potential distribution of the Iberian *Abies* species: a phytogeographic approach using fossil pollen data and species distribution models. *Diversity and Distributions* 16, 2 (2010), 214–228.
- [2] ALLOUCHE, O., TSOAR, A., AND KADMON, R. Assessing the accuracy of species distribution models: prevalence, kappa and the true skill statistic (TSS). *Journal of applied ecology* 43, 6 (2006), 1223–1232.
- [3] ARISTA, M., AND TALAVERA, S. Phenology and anatomy of the reproductive phase of *Abies pinsapo* Boiss. (Pinaceae). *Botanical Journal of the Linnean Society* 116, 3 (1994), 223–234.
- [4] BREIMAN, L. Random forests. *Machine learning* 45, 1 (2001), 5–32.
- [5] ELITH, J., AND LEATHWICK, J. R. Species distribution models: ecological explanation and prediction across space and time. *Annual review of ecology, evolution, and systematics* 40 (2009), 677–697.
- [6] FARR, T. G., ROSEN, P. A., CARO, E., CRIPPEN, R., DUREN, R., HENSLEY, S., KOBRICK, M., PALLER, M., RODRIGUEZ, E., ET AL. The Shuttle Radar Topography Mission. *Reviews of geophysics* 45, 2 (2007).
- [7] FICK, S. E., AND HIJMANS, R. J. WorldClim 2: new 1-km spatial resolution climate surfaces for global land areas. *International journal of climatology* 37, 12 (2017), 4302–4315.
- [8] FIELDING, A. H., AND BELL, J. F. A review of methods for the assessment of prediction errors in conservation presence/absence models. *Environmental conservation* 24, 1 (1997), 38–49.

- [9] FRIEDMAN, J. H. Greedy function approximation: a gradient boosting machine. *Annals of statistics* (2001), 1189–1232.
- [10] GBIF.ORG. Global Biodiversity Information Facility (GBIF) occurrence download, 2023. Accedido mediante la interfaz de consulta de datos de presencia en R (rgbif). <https://www.gbif.org/>.
- [11] GREENWELL, B. M. pdp: An R package for constructing partial dependence plots. *The R Journal* 9, 1 (2017), 421–436.
- [12] HIJMANS, R. J. *terra: Spatial Data Analysis*, 2023. R package. <https://CRAN.R-project.org/package=terra>.
- [13] HUTCHINSON, G. E. Concluding remarks. *Cold Spring Harbor Symposia on Quantitative Biology* 22 (1957), 415–427.
- [14] IUCN. The IUCN red list of threatened species. version 2017-3, 2017. <http://www.iucnredlist.org>.
- [15] KUHN, M. Building predictive models in R using the caret package. *Journal of statistical software* 28, 5 (2008), 1–26.
- [16] LINARES, J. C. Biogeography and evolution of *Abies* (Pinaceae) in the Mediterranean Basin: the roles of long-term climatic change and glacial refugia. *Journal of Biogeography* 38, 4 (2011), 619–630.
- [17] LÓPEZ LEÓN, F. J. tfg-sdm-pinsapo: Modelización del hábitat y vulnerabilidad climática del *Abies pinsapo* Boiss mediante Machine Learning, 2026. <https://github.com/fralopleo2/tfg-sdm-pinsapo>.
- [18] McCULLAGH, P., AND NELDER, J. A. *Generalized Linear Models*, 2nd ed. Chapman and Hall/CRC, 1989.
- [19] MINISTERIO PARA LA TRANSICIÓN ECOLÓGICA Y EL RETO DEMOGRÁFICO (MITECO). Evaluación de la vulnerabilidad y situación futura frente al cambio climático: *Abies pinsapo*. Tech. rep., Dirección General de Biodiversidad, Bosques y Desertificación, Gobierno de España, Madrid, España, 2012. Inventario Nacional de Biodiversidad. https://www.miteco.gob.es/content/dam/miteco/es/biodiversidad/temas/inventarios-nacionales/Abies_pinsapo_tcm30-200313.pdf.

- [20] R CORE TEAM. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria, 2023. <https://www.R-project.org/>.
- [21] ROBIN, X., TURCK, N., HAINARD, A., TIBERTI, N., LISACEK, F., SANCHEZ, J.-C., AND MÜLLER, M. pROC: an open-source package for R and S+ to analyze and compare ROC curves. *BMC bioinformatics* 12 (2011), 1–8.
- [22] TOBLER, W. R. A computer movie simulating urban growth in the Detroit region. *Economic geography* 46, sup1 (1970), 234–240.
- [23] VALAVI, R., ELITH, J., LAHOZ-MONFORT, J. J., AND GUILLERA-ARROITA, G. blockCV: An R package for generating spatially or temporally independent training and testing folds for species distribution models. *Methods in Ecology and Evolution* 10, 2 (2019), 225–232.
- [24] ZUUR, A. F., IENO, E. N., AND ELPHICK, C. S. A protocol for data exploration to avoid common statistical problems. *Methods in ecology and evolution* 1, 1 (2010), 3–14.